

Uma Análise Comparativa entre NeRFs Few-Shot e Per-Scene aplicadas em Conjuntos de Dados de Vistas Esparsas

Felipe Gda Silva¹

¹Departamento de Ciências da Computação e Estatística – UNESP
CEP: 15054-000 – São José do Rio Preto – SP – Brazil

`felipe-gomes.silva@unesp.br`

Abstract. *This work compares Generalizable NeRFs and Fast Optimization Per-Scene trained models applied to sparse-view datasets, evaluating the impact of these feature extraction architectures on novel view synthesis performance. Through a quantitative analysis using visual fidelity (PSNR, SSIM, LPIPS) and computational efficiency metrics (convergence time, VRAM footprint, inference time), this study highlights the trade-offs between the global generalization of Transformers and the local processing efficiency of convolutions, as well as the critical impact of spatial scale mismatch in per-scene optimized models. Ultimately, it aims to guide the selection of 3D rendering models for practical scenarios often constrained by hardware limitations and data scarcity.*

Resumo. *Este trabalho apresenta uma análise comparativa entre modelos generalizáveis via extratores de características e modelos de otimização rápida por cena aplicados em conjuntos de dados com vistas esparsas, avaliando o impacto dessas arquiteturas no desempenho de síntese de novas vistas. Por meio de uma investigação quantitativa baseada em métricas de fidelidade visual (PSNR, SSIM e LPIPS) e de eficiência computacional (tempo de convergência, consumo de VRAM e tempo de inferência), o estudo quantifica os compromissos entre a capacidade de generalização global dos Transformers e a eficiência de processamento local das convoluções. O objetivo principal consiste em estabelecer diretrizes empíricas robustas para a seleção de modelos NeRF em cenários severamente limitados por escassez de dados e restrições práticas de hardware.*

1. Introdução

Modelos de campos de radiância neural (NeRF) consolidaram-se, nos anos recentes, como o estado da arte, tanto na indústria, quanto na academia, sobre geração de novas vistas [Kerbl et al. 2023, Tancik et al. 2023, Adobe 2025]. Entretanto, as mais avançadas técnicas de renderização neural demandam de enormes quantias de: (i) poder computacional; (ii) múltiplas vistas no conjunto de dados. Ambos os desafios inviabilizam aplicações práticas como escaneamento mobile, provedores virtuais e síntese em conjuntos de dados reduzidos. É com tal problemática que projetos como Instant-NGP (*Instant Neural Graphics Primitives*), Nerfacto, Pixel-Nerf, Gnt (*Generalizable Nerf Transformer*) [Müller et al. 2022, Tancik et al. 2023, Yu et al. 2021, Wang et al. 2023], entre outros, tentam expandir o estado da arte e, consequentemente, abordam temas análogos, como: (i) *encoding* espacial de parâmetros [Müller et al. 2022]; (ii) uso de arquiteturas híbridas entre Convolutional Neural Networks (CNN) e Vision Transformers (ViT)

[Schwarz et al. 2021, Wu et al. 2021, Wang et al. 2023]; e (iii) pré-computação (*baking*) dos modelos em estruturas de menor pegada de memória [Hedman et al. 2021].

Este trabalho tem, por conseguinte, o objetivo de explorar o uso dos diferentes modelos de campos de radiância neural e suas respectivas técnicas de otimização, ao aplicá-las em conjuntos de dados com vistas esparsas, promovendo uma análise exploratória entre desempenho computacional e qualidade dos volumes gerados. Para avaliar a fidelidade das reconstruções, serão utilizadas métricas de qualidade visual amplamente consagradas na literatura, como PSNR (*Peak Signal-to-Noise Ratio*), SSIM (*Structural Similarity Index Measure*) [Wang et al. 2004] e LPIPS (*Learned Perceptual Image Patch Similarity*) [Zhang et al. 2018]. Paralelamente, a quantificação do custo operacional basear-se-á em métricas de desempenho sistêmico, incluindo o tempo de convergência no treinamento, a velocidade de inferência e a pegada de memória (*memory footprint*), sobretudo o consumo de VRAM (*Video Random Access Memory*). Embora trabalhos como [Niemeyer et al. 2022] e [Heo et al. 2023] tenham avaliado NeRFs em regimes de dados limitados e trabalhos como NerfBaselines [Kulhanek and Sattler 2025] tenham constatado resultados em NeRFs tradicionais e baseados em treinamento por cena, a comparação sistemática entre modelos generalizáveis com extratores convolucionais versus baseados em atenção, sob condições controladas de hardware e splits reproduzíveis, permanece inexplorada na literatura. Em suma, esta investigação fornece um panorama consolidado sobre os *trade-offs* entre eficiência computacional e fidelidade visual, estabelecendo diretrizes claras para a viabilização e aplicação prática de modelos de síntese de novas vistas em cenários com restrições das mais diversas, especialmente de dados e de hardware.

Diante desta problemática, as contribuições deste trabalho são: (i) uma avaliação sistemática e reproduzível de modelos NeRF few-shot e per-scene sob três regimes de dados; (ii) a disponibilização pública de wrappers de integração do PixelNeRF e GNT ao framework Nerfstudio em <https://github.com/felipe-gsilva/few-shot-nerfs> adaptando suas interfaces de entrada e saída para conformidade com o protocolo de avaliação unificado do framework, sem modificação dos pesos pré-treinados ou da lógica de inferência original, de modo a permitir comparação reproduzível sob condições controladas.

2. Fundamentação Teórica

Conjuntos de Dados de Vistas Esparsas. Essa nomenclatura refere-se, neste trabalho, aos conjuntos de dados imagéticos que possuem pouca (ou nenhuma) redundância e/ou variabilidade de poses de câmera referentes ao mesmo objeto. Áreas como histologia, holotomografia e microscopia confocal de fluorescência ilustram bem esse problema: a aquisição de imagens multi-vista é fisicamente limitada, biologicamente invasiva e estruturalmente esparsa por natureza [Xue et al. 2021].

Campos de Radiância Neural. Campos de Radiância Neural (*Neural Radiance Fields*, NeRF) utilizam-se de redes neurais do tipo MLP (*Multilayer Perceptron*) para aproximar uma função contínua no espaço 5D [Mildenhall et al. 2020]. Essa função recebe como entrada uma posição espacial $\mathbf{x} = (x, y, z)$ e uma direção de visualização $d = (\theta, \phi)$, retornando a densidade volumétrica $\sigma(\mathbf{x})$ e a cor associada $\mathbf{c} = (r, g, b)$:

$$F_{\theta} : F_{\theta} \circ \gamma(\mathbf{x}, d) \rightarrow (\sigma, \mathbf{c}), \quad \sigma \in \mathbb{R}_{\geq 0}, \quad \mathbf{c} \in [0, 1]^3$$

onde θ representa os pesos da rede neural, sendo F_{θ} o MLP original e γ um codificador posicional.

Representações de Cena. Trabalhos subsequentes introduziram representações híbridas que desacoplam a estrutura espacial da rede neural, dado a viabilidade de alterar-se o *positional encoding* via codificação de fourier por um sistema de *hash encoding*. O Instant-NGP [Müller et al. 2022] propõe uma codificação por tabela de hash multiescala, que mapeia coordenadas espaciais em vetores de características de forma eficiente, reduzindo drasticamente o tempo de otimização por cena. O Nerfacto [Tancik et al. 2023] estende essa ideia combinando múltiplas otimizações comprovadas da literatura focando no equilíbrio entre qualidade visual e tempo de renderização em tempo real.

Renderização Volumétrica. Seja um campo de radiância neural F_{θ} , a cor esperada de um pixel é computada através de renderização volumétrica. Dado um raio $\mathbf{r}(t) = \mathbf{o} + t\mathbf{d}$ com limites de profundidade (t_n, t_f) , a cor resultante é dada pela integral:

$$\hat{C}(\mathbf{r}) = \int_{t_n}^{t_f} T(t) \sigma(\mathbf{r}(t)) \mathbf{c}(\mathbf{r}(t), \mathbf{d}) dt$$

onde $T(t) = \exp\left(-\int_{t_n}^t \sigma(\mathbf{r}(s)) ds\right)$ denota a transmitância acumulada ao longo do raio, ou seja, a probabilidade de o raio não atingir nenhuma partícula obstrutiva até a profundidade t . Na prática, por ser uma função contínua, essa integral é aproximada numericamente via *alpha compositing* sobre amostras discretas interpoladas ao longo de cada raio durante o treinamento.

Extrator de Características. O extrator de características se torna, portanto, responsável por codificar as imagens de entrada em representações que a rede neural possa condicionar. O PixelNeRF [Yu et al. 2021] utiliza uma ResNet (*Residual Neural Network*) pré-treinada para extrair mapas de características por imagem; dado um ponto 3D, sua projeção nas vistas de entrada recupera os vetores de características espaciais correspondentes, que são agregados e passados à MLP de radiância. Essa abordagem é local e opera por pixel, sem modelar explicitamente relações entre vistas. O GNT (Generalizable NeRF Transformer) [Wang et al. 2023] substitui: (i) o extrator de características por um *transformer* capaz de utilizar de mecanismos de atenção para angariar características mais globais ao objeto; (ii) a MLP de radiância também por um *transformer* que amostra pontos ao longo do raio e agrega informação entre vistas por meio de atenção cruzada, eliminando a dependência de uma função de volume explícita.

NeRFs Few-Shot vs. Per-Scene. Com o objetivo de reduzir a necessidade de múltiplas vistas durante o treinamento, surgiram abordagens conhecidas como NeRFs *few-shot*, capazes de generalizar a cena e produzir novas vistas a partir de poucas imagens, utilizando-se de diversos conceitos distintos aplicados aos componentes NeRF supracitados. Estas abordagens contrastam frontalmente com os métodos *per-scene*. Enquanto modelos *per-scene* (como Instant-NGP) otimizam uma estrutura de dados de forma isolada e colapsam sob a escassez de vistas, arquiteturas *few-shot* e generalizáveis incorporam *priors* estruturais e semânticos aprendidos de grandes bases de dados. Essa distinção arquitetural torna-se indispensável em cenários onde a extração é severamente restrita.

3. Metodologia

Esta seção contempla a metodologia adotada para a realização dos experimentos, incluindo a descrição dos conjuntos de dados utilizados, os modelos de NeRF selecionados para o estudo comparativo, as métricas de avaliação aplicadas e o ambiente computacional onde os testes foram conduzidos.

Modelos sem integração nativa ao Nerfstudio (PixelNeRF e GNT) foram portados para o framework seguindo sua interface modular, de modo a viabilizar a sua respectiva comparação. A seguir, apresentam-se os modelos selecionados.

3.1. Modelos Selecionados

Neste trabalho, são avaliados modelos representativos para reconstrução de campos de radiância neural em cenários de poucas vistas (*few-shot*), contemplando diferentes paradigmas arquiteturais e estratégias de aprendizado. Especificamente, consideram-se:

1. PixelNeRF [Yu et al. 2021], que utiliza redes neurais convolucionais para extrair características espaciais das imagens e inseri-las no renderizador através de interpolação e projeção;
2. Generalizable NeRF Transformer (GNT) [Wang et al. 2023], que emprega mecanismos de atenção (*Transformers*) em ambos os componentes NeRF, substituindo tanto o extrator de características quanto o renderizador diferenciável por módulos baseados em atenção cruzada;

Para fins de linha de base (baseline) comparativa, este estudo também avalia métodos *per-scene* sob regime de dados limitados:

1. Instant-NGP [Müller et al. 2022], que substitui a MLP tradicional por uma codificação em tabela de hash multiescala, permitindo otimização por cena em tempo significativamente reduzido; e
2. Nerfacto [Tancik et al. 2023], modelo focado em eficiência que agrega as melhores heurísticas da literatura para proporcionar alta qualidade e treinamento rápido.

A fim de justificar a seleção das linhas de base, ressalta-se a ausência de outras arquiteturas seminais no protocolo de avaliação. A restrição aos modelos selecionados visa manter o foco no contraste metodológico entre abordagens generalizáveis (via extração de características) e estruturas explícitas otimizadas por cena, evitando a explosão combinatória do estudo. A seguir, detalham-se as motivações técnicas para a exclusão de arquiteturas proeminentes:

- **RegNeRF:** Embora seja o estado da arte em cenários de poucas vistas, sua premissa central baseia-se na aplicação de *priors* geométricos e na regularização de semântica e profundidade em poses não observadas, frequentemente utilizando fluxos normalizadores (*normalizing flows*). Como o escopo deste trabalho reside em avaliar a capacidade intrínseca de generalização dos extratores de características (CNNs vs. Transformadores) e a eficiência estrutural de representações por *hash*, a inclusão de um método fortemente baseado em regularização de otimização desviaria o foco analítico.

- **MVSNeRF:** Apesar de ser um modelo generalizável robusto, sua arquitetura fundamenta-se na construção de volumes de custo 3D (*cost volumes*) baseados em princípios de *Multi-View Stereo* (MVS). Esta formulação impõe uma dinâmica de uso de memória e um paradigma de reconstrução geométrica que diferem substancialmente da codificação direta por projeção 2D (PixelNeRF) ou da agregação puramente atencional (GNT), inviabilizando uma omparação equitativa no que tange ao *footprint* de VRAM.
- **Mip-NeRF 360:** Projetado especificamente para mitigar o problema de aliasing e parametrizar o espaço de forma não linear em cenas abertas e irrestritas (*unbounded 360-degree*). Dado que o protocolo experimental deste estudo adota o dataset LLFF, caracterizado majoritariamente por capturas frontais de profundidade delimitada (*forward-facing*), a principal contribuição do Mip-NeRF 360 torna-se mecanicamente subutilizada. Ademais, sem acoplamento a estratégias de regularização *few-shot*, o modelo sofre degradação análoga aos métodos *per-scene* já representados de forma mais eficiente pelo Instant-NGP e Nerfacto.

A seleção e exclusão dos modelos supracitados visa proporcionar uma análise abrangente entre diferentes abordagens, cobrindo métodos baseados em CNNs, transformadores, reconstrução volumétrica explícita e modelos generativos baseados em representações por hash *per-scene*. Essa diversidade permite avaliar a qualidade de reconstrução em cenários com vistas limitadas e o compromisso entre generalização e custo computacional, bem como o impacto de estratégias distintas nos três regimes de avaliação considerados, como observado na seção 3.2.

3.2. Regimes Explorados

Os experimentos foram organizados em três regimes:

- **Per-Scene:** Representa o limite superior de fidelidade visual, no qual os modelos são otimizados a partir do zero utilizando a totalidade das imagens disponíveis para aquela cena específica, demandando um tempo de convergência expressivo em troca de alta qualidade de reconstrução;
- **Test-Time Adaptation (TTA):** Constitui um regime intermediário e eficiente sob a perspectiva temporal, em que de 3 a 10 imagens da nova cena alimentam o modelo generalizável pré-treinado por meio de poucos passos de sintonia fina (*fine-tuning*), permitindo a adaptação rápida e a correção de discrepâncias geométricas com baixo custo computacional;
- **Zero-Shot:** Consiste no paradigma ideal para cenários com restrições extremas de tempo de processamento e energia, em que a inferência é realizada instantaneamente a partir dos pesos genéricos pré-carregados, sem demandar qualquer etapa de treinamento ou otimização local na nova cena.

3.3. Implementação no Nerfstudio

Os modelos foram implementados no framework *Nerfstudio* [Tancik et al. 2023], seguindo sua arquitetura modular. As adaptações concentraram-se nos componentes *DataManager* e *Pipeline*, responsáveis pelo carregamento das vistas de entrada e pela agregação das características multi-vista, respectivamente, mantendo inalterados os módulos de renderização e avaliação nativos do framework. A adoção de um framework unificado assegura equivalência no protocolo de avaliação entre os modelos, eliminando variáveis de

implementação que poderiam comprometer a comparação, visto que o *Nerfstudio* oferece, ademais, um conjunto de utilitários aproveitados neste trabalho:

1. visualização em tempo real por meio de interface gráfica interativa, permitindo monitorar o treinamento e inspecionar qualitativamente os resultados de renderização durante o processo;
2. aceleração via GPU com suporte a CUDA, integrada à biblioteca *tiny-cuda-nn* [Müller 2021], que fornece implementações otimizadas de MLPs e codificações de entrada diretamente em kernels CUDA, com ganho de desempenho reportado entre $5\times$ e $30\times$ em relação a implementações PyTorch convencionais, dependendo da arquitetura e do cenário de uso; e
3. infraestrutura de logging e exportação de métricas, incluindo salvamento de checkpoints e integração com *Weights & Biases*, que padroniza o registro dos experimentos entre os diferentes modelos.

Dentre os modelos avaliados, o Instant-NGP e o Nerfacto encontram-se nativamente integrados ao *Nerfstudio*, dispensando adaptações de implementação. Os demais modelos (PixelNeRF e GNT) foram portados para o framework a partir de suas implementações originais, com adaptações nos componentes de *DataManager*, *Pipeline* e *model* para conformidade com a interface do *Nerfstudio*, ambos utilizando-se do otimizador Adam (otimizado pelo *tinycudann*) com *learning rate* $\eta = 10^{-3}$ e *weight decay* = 0.0. Cabe ressaltar que a literatura original do GNT e PixelNeRF sugere taxas de aprendizado menores (entre 10^{-4} e 5×10^{-4}). A adoção de $\eta = 10^{-3}$ neste trabalho visa puramente padronizar os hiperparâmetros de base entre todos os modelos avaliados, um critério que pode influenciar secundariamente a estabilidade do TTA.

As implementações foram guiadas pelas descrições metodológicas dos trabalhos originais, mantendo equivalência funcional. A implementação completa encontra-se disponível em <https://github.com/felipe-gsilva/few-shot-nerfs>.

3.4. Protocolo Experimental

Os experimentos foram conduzidos sobre o dataset LLFF (*Local Light Field Fusion*) [Mildenhall et al. 2019], [Mildenhall et al. 2020], composto por cenas de objetos reais capturadas com câmera em movimento frontal. A escolha pelo LLFF em detrimento de alternativas tradicionais como o DTU baseia-se diretamente nas severas restrições de hardware físico do presente estudo. Especificamente, o processamento dos volumes de custo tridimensionais (*cost volumes*) exigidos pelo DTU em sua resolução original demanda um volume de memória gráfica que excede a capacidade de 6 GB de VRAM da GPU utilizada. Dessa forma, o LLFF apresenta-se como a única opção viável que concilia relevância científica com a limitação de recursos físicos, sendo compatível com o protocolo de avaliação clássico de [Niemeyer et al. 2022]. Reserva-se, portanto, para teste as imagens cujo índice é múltiplo de 8 (*llffhold*=8), totalizando entre 2 e 4 imagens de teste por cena.

A seleção das vistas de treino ($N \in \{3, 6, 10\}$) foi realizada por duas estratégias distintas: (i) *uniform*, em que as vistas são amostradas por interpolação linear sobre os índices do dataset, distribuindo-as uniformemente ao longo da trajetória da câmera; e (ii) *random*, em que as vistas são sorteadas aleatoriamente com semente fixa (42), garantindo

reprodutibilidade. A comparação entre as duas estratégias permite avaliar a sensibilidade dos modelos à distribuição espacial das vistas de entrada.

Tabela 1. Impacto da estratégia de seleção de vistas de treino (*uniform* vs. *random*) sobre a qualidade visual média no dataset LLFF, avaliado no regime TTA com $N = 10$ vistas. Resultados reportado sobre a cena *fern*.

Modelo	Split	PSNR (dB) $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$	Δ PSNR (<i>unif. – rand.</i>)
PixelNeRF	Uniform	6.98	0.047	0.846	+0.54
	Random	6.44	0.042	0.840	
GNT	Uniform	10.34	0.179	0.738	+0.15
	Random	10.19	0.184	0.742	
Instant-NGP	Uniform	13.57	0.231	0.627	+0.06
	Random	13.51	0.229	0.630	
Nerfacto	Uniform	12.04	0.227	0.809	+0.11
	Random	11.93	0.226	0.865	

As métricas finais são reportadas exclusivamente sobre o conjunto de teste, sem sobreposição com as vistas de treino. Todos os experimentos foram executados em uma GPU NVIDIA GeForce GTX 1660 Super (6GB de VRAM), com CUDA 12.6 e driver 610.43.02. Para garantir reprodutibilidade em diferentes arquiteturas, utilizou-se contêineres Docker com o runtime NVIDIA para garantir isolamento do ambiente e reprodutibilidade entre diferentes hosts com GPU compatível.

3.5. Métricas de Avaliação


A avaliação dos modelos contempla três dimensões complementares: qualidade visual, eficiência computacional e pegada de memória. Para a qualidade visual, são empregadas três métricas amplamente adotadas na literatura de síntese de novas vistas: (i) PSNR (*Peak Signal-to-Noise Ratio*), que mede a fidelidade pixel a pixel entre a imagem renderizada e a imagem de referência em escala logarítmica, sendo sensível a erros de brilho e cor; (ii) SSIM (*Structural Similarity Index Measure*) [Wang et al. 2004], que avalia a similaridade estrutural entre imagens considerando luminância, contraste e estrutura, sendo mais correlacionado com a percepção humana do que o PSNR; e (iii) LPIPS (*Learned Perceptual Image Patch Similarity*) [Zhang et al. 2018] usando a rede VGG (Visual Geometry Group) como extrator de características, seguindo o protocolo de [Niemeyer et al. 2022] para quantificar a distância perceptual entre imagens (valores menores indicam maior similaridade perceptual). Para a eficiência computacional, é medida a taxa de renderização em quadros por segundo (*fps*), avaliada durante a inferência sobre as câmeras do conjunto de teste. Para a pegada de memória, é reportado o footprint de parâmetros do modelo, calculado como a soma do produto entre o número de parâmetros e o tamanho de cada elemento em bytes. Também comparou-se os respectivos tamanhos de parâmetros com a quantidade de memória alocada no torch naquele dado momento. Como o ambiente de GPU é controlado (reservado pelo ambiente docker), possíveis outros processos simultâneos não adicionaram ruído às métricas de avaliação.

As avaliações de qualidade visual são realizadas sobre o conjunto de teste gerado pelo protocolo de split descrito na Seção 3.4, utilizando o *dataloader* de avaliação do *Nerfstudio* (`fixed_indices_eval_dataloader`), que itera sobre câmeras fixas e compara as imagens renderizadas (`outputs["rgb"]`) com as imagens de referência (`batch["image"]`) sem amostras das vistas de treino.

4. Experimentos e Resultados

A seguir, destacam-se os principais resultados do treinamento, que levou, ao todo, cerca de 180 horas para ser completado. A Figura 1 ilustra o protocolo de execução adotado. Segmenta-se esta seção entre uma análise quantitativa, qualitativa e computacional, respectivamente.

Figura 1. Protocolo de execução experimental. As caixas superiores representam as etapas do pipeline; as ramificações inferiores detalham as variantes de configuração (estratégia de split, regime de treino) e as métricas coletadas. Todo o ambiente foi isolado via contêiner Docker com GPU reservada.



GPU reservada via Docker \ NVIDIA GTX 1660 Super (6 GB) \ CUDA 12.6 \ ~180h de execução total

4.1. Análise Quantitativa

A análise quantitativa seguiu o protocolo experimental descrito na Seção 3, comparando as métricas LPIPS, SSIM e PSNR (Seção 3.5) entre todos os modelo e regimes de treino. A Tabela 2 apresenta as métricas escolhidas:

Tabela 2. Avaliação quantitativa da qualidade visual no dataset LLFF. As setas indicam se valores maiores ($\uparrow$) ou menores ($\downarrow$) representam desempenho superior. Aviso: Comparações cruzadas entre o bloco de Generalizáveis (avaliado em downscale 4) e o bloco Per-Scene (avaliado na resolução nativa) não são equitativas devido ao fenômeno de scale mismatch.

Regime	Modelo	PSNR (dB) $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$
Avaliação em downscale 4 (Generalizáveis e Per-Scene)				
Zero-Shot	PixelNeRF	5.75	0.065	0.850
	GNT	10.34	0.179	0.738
TTA ($N = 3$)	PixelNeRF	6.60	0.059	0.829
	GNT	10.19	0.184	0.742
TTA ($N = 6$)	PixelNeRF	6.52	0.060	0.831
	GNT	10.19	0.184	0.742
TTA ($N = 10$)	PixelNeRF	6.98	0.047	0.846
	GNT	10.34	0.179	0.738
Per-Scene (100%)	Instant-NGP	15.29	0.545	0.358
	Nerfacto	25.33	0.853	0.161
Avaliação em downscale 8 (Modelos Per-Scene na resolução nativa)				
Per-Scene (100%)	Instant-NGP	13.57	0.440	0.507
	Nerfacto	26.25	0.843	0.205

Como referência externa, a Tabela 3 compila resultados reportados pelo *NerfBaselines* [Kulhanek and Sattler 2025] para o LLFF, um dataset predominantemente *forward-facing* para o qual métodos NeRF costumam empregar parametrização em espaço NDC. Estes números são apresentados apenas como comparativo de literatura para um limiar superior (protocolo/hardware podem divergir do presente estudo).

Tabela 3. Resultados no LLFF reportados pelo *NerfBaselines* [Kulhanek and Sattler 2025]. "Time" refere-se ao tempo total de treinamento reportado e "GPU mem." ao pico de memória alocada durante o treino.

Modelo	PSNR (dB) $\uparrow$	SSIM $\uparrow$	LPIPS (VGG) $\downarrow$	Time	GPU mem. (GB)
Mip-NeRF 360	26.59	0.846	0.168	9h 55m 23s	104.98
TensoRF	26.68	0.834	0.202	31m 32s	20.38

A tabela 3 demonstra um bom limite certamente não alcançável com a tecnologia de vistas esparsas empregadas neste trabalho, visto que a natureza do treino se difere ao

permitir que o dataset inteiro seja utilizado sem downscale algum. Entretanto, estas métricas são apresentadas apenas como referência de limite superior de qualidade possível.

4.2. Análise Qualitativa

A análise qualitativa seguiu as estruturas do split (3.4), sendo possíveis renderizações do volume em projeções tanto ortográficas quanto perspectivas. Para facilitar a identificação visual, optou-se por utilizar o acúmulo dos raios em projeção perspectiva, requerindo à rede vistas já conhecidas (com os dados de câmera existentes do conjunto de teste). Destaca-se, a seguir, os principais resultados visuais:




Figura 2. Comparação qualitativa para a cena "Fern" do dataset LLFF. PixelNeRF e GNT operam no regime TTA (10 vistas), enquanto Instant-NGP e Nerfacto operam no regime Per-Scene.

Nota-se que o PixelNeRF produz renderizações com forte desfoque isotrópico, típico de falha de localização de características por projeção 2D em vistas esparsas. O GNT preserva contornos mais nítidos, mas apresenta artefatos de cor em regiões de baixa redundância entre vistas. O Instant-NGP per-scene exibe flutuações de densidade volumétrica em regiões não cobertas de modo denso, enquanto o Nerfacto per-scene produz a reconstrução mais fiel em sua resolução nativa.

4.3. Trade-offs Computacionais

Tabela 4. Comparativo de custo computacional e pegada de memória. O tempo de treinamento refere-se à convergência da cena (ou adaptação no caso TTA). O "Tamanho da Rede" indica o footprint estático alocado, enquanto o "Pico Torch" demonstra o pico real de memória na GPU aferido dinamicamente durante a inferência. A taxa de FPS foi medida na renderização do conjunto de teste.

Modelo	Regime	Tempo de Treino	Tamanho da Rede (GB)	Pico Torch (GB)	Inferência (FPS)
PixelNeRF	Zero-Shot (0)	N/A (Pré-treinado)	1.93	3.42	0.006
GNT	Zero-Shot (0)	N/A (Pré-treinado)	1.93	0.19	0.008
PixelNeRF	TTA (10)	12 min 42 s	1.93	3.42	0.006
GNT	TTA (10)	06 min 54 s	1.93	0.19	0.008
Instant-NGP	Per-Scene	41 min 02 s	0.01	0.15	0.160
Nerfacto	Per-Scene	21 min 52 s	0.02	0.05	0.203

Por fim, ressalta-se que todos os experimentos foram executados de forma única e exclusiva sobre a cena *fern* do conjunto de dados LLFF. Essa decisão metodológica justifica-se pelo elevado custo de processamento exigido pelos modelos sob regime de Test-Time Adaptation (TTA), bem como pelo longo tempo total necessário para a convergência das demais variantes. Dessa forma, a cena *fern* foi adotada como um estudo de caso representativo para viabilizar a validação completa do pipeline sob as restrições práticas de hardware, servindo como base sólida antes de uma eventual expansão para as demais cenas do dataset.




Figura 3. Trade-off entre Fidelidade Visual (PSNR) e Consumo de VRAM (10 vistas ou regime per-scene). O quadrante superior esquerdo representa a região ideal (alta qualidade, baixo custo).

4.4. O Fenômeno do Scale Mismatch

O modelo Nerfacto obteve um desempenho notável de 26,25 dB de PSNR quando treinado e avaliado na sua resolução nativa inicial (downscale 8). No entanto, em experimentos preliminares, ao inferir esse mesmo modelo numa resolução superior (downscale 4), a sua qualidade visual degradava severamente para 12,04 dB. Este fenômeno de *Scale Mismatch* (incompatibilidade de escala) evidenciava uma vulnerabilidade inerente às arquiteturas *per-scene* que empregam tabelas de hash multiescala, pois estas são otimizadas para codificar a cena estritamente nas frequências espaciais presentes nas imagens de treino.

Para validar essa hipótese e contornar a limitação, o modelo Nerfacto foi retreinado nativamente na resolução de downscale 4. Com a grade de características adequadamente ajustada para as altas frequências dessa nova escala, o desempenho saltou expressivamente para 25,33 dB de PSNR e 0,853 de SSIM. Esse resultado confirma que a arquitetura Nerfacto possui alta capacidade de reconstrução em maiores resoluções, desde que o processo de otimização (e consequentemente o *footprint* das estruturas de hash) seja instanciado na escala alvo correspondente.

4.5. Catastrophic Forgetting e Inércia no TTA

A adaptação em tempo de teste (*Test-Time Adaptation* - TTA) visa ajustar os pesos de um modelo generalizável previamente treinado para uma nova cena utilizando um número muito restrito de vistas. Observou-se, entretanto, um comportamento singular no GNT. O modelo GNT no regime Zero-Shot obteve exatos 10,34 dB de PSNR com 10 vistas, valor numericamente idêntico ao seu desempenho após o TTA. A equivalência numérica entre Zero-Shot e TTA ($N = 10$) para o GNT sugere que as iterações de *fine-tuning* não produzem adaptação significativa na cena avaliada. Esse comportamento é consistente com a hipótese de inércia induzida pelo *prior* global do transformer — que, ao contrário das camadas convolucionais do PixelNeRF, resiste ao sobreajuste por distribuir a informação de cada cena de forma difusa ao longo de todos os cabeçotes de atenção. Uma análise ablativa comparando a norma dos gradientes durante o TTA de ambos os modelos permitiria discriminar entre inércia arquitetural e instabilidade de otimização; é imperativo reconhecer que o *learning rate* adotado (10^{-3}) pode ter sido excessivo para as etapas de *fine-tuning* do transformer em TTA. Em contraste, o PixelNeRF demonstrou maior plasticidade, elevando o desempenho de 5,75 dB (Zero-Shot) para 6,98 dB (TTA 10), confirmando que sua arquitetura híbrida com CNNs permite uma especialização *per-scene* mais maleável, ainda que seu teto de qualidade visual se mantenha estruturalmente inferior ao GNT.

5. Conclusões

Este trabalho apresentou uma análise comparativa entre modelos NeRF generalizáveis (PixelNeRF, GNT) e modelos de otimização por cena (Instant-NGP, Nerfacto) em regimes de vistas esparsas, sob protocolo unificado no framework Nerfstudio. Os resultados parciais obtidos sobre o dataset LLFF revelam tendências que permitem delinear conclusões relevantes sobre os *trade-offs* entre fidelidade visual, generalização de escala espacial e custo computacional.

No eixo de qualidade visual, os resultados revelam o comportamento esperado das diferentes arquiteturas. Os modelos generalizáveis exibem robustez notável sob diferentes resoluções: o GNT mantém um desempenho estável em torno de 10,34 dB de PSNR e 0,738 de LPIPS tanto no downscale 8 quanto no downscale 4, evidenciando a eficácia da agregação global por atenção cruzada em seu extrator de características. O PixelNeRF demonstra uma evolução coerente sob Test-Time Adaptation (TTA), subindo de 5,75 dB (Zero-Shot) para 6,98 dB ($N = 10$).

Em contrapartida, os modelos *per-scene* evidenciam uma forte dependência da escala de treinamento. Quando treinado e avaliado em sua resolução nativa inicial (downscale 8), o Nerfacto atingiu a marca superior de 26,25 dB de PSNR. Contudo, demonstrou-se que tentar inferir esse modelo em resoluções superiores (downscale 4) causava degradação severa devido ao *Scale Mismatch* (caindo para 12,04 dB). Ao corrigir essa incompatibilidade por meio do retreino nativo do Nerfacto diretamente em downscale 4, o modelo recuperou sua excelência, atingindo 25,33 dB de PSNR e 0,853 de SSIM. Esse fenômeno realça que representações implícitas/híbridas baseadas em hash multiescala requerem pareamento estrito entre a resolução de treino e inferência, ao passo que os modelos generalizáveis providos de redes convolucionais e mecanismos de atenção global acomodam variações de resolução de maneira inerente.

Contudo, a análise computacional revela um *trade-off* não trivial. Os modelos generalizáveis dispensam otimização por cena no regime *zero-shot* e requerem adaptação mínima no TTA (12 min para PixelNeRF; 06 min 54 s para GNT), enquanto os modelos *per-scene* demandam tempos de convergência significativamente maiores (~ 22 min para Nerfacto; ~ 41 min para Instant-NGP com 10 vistas). Em contrapartida, os modelos *per-scene* apresentaram taxas de inferência superiores (0,203 FPS para Nerfacto vs. 0,006 FPS para PixelNeRF), com um pico dinâmico de VRAM substancialmente menor (0,05 GB vs. 3,42 GB) durante a renderização. Esses resultados indicam que, em cenários onde a latência de inferência e os requisitos de hardware são críticos, a exemplo de aplicações *mobile* ou sistemas embarcados, os métodos *per-scene* podem ser preferíveis mesmo com o custo adicional de treinamento.

É necessário ressaltar que os resultados reportados são parciais, restritos à cena *fern* do LLFF, e a generalização para o conjunto completo de 8 cenas requer execuções adicionais. O desempenho excepcionalmente baixo do PixelNeRF ($< 7,0$ dB) indica limitações inerentes de sua arquitetura local baseada em projeção 2D de características em vistas extremamente esparsas sem modelagem atencional de contexto global. Além disso, a estabilidade das métricas de TTA do GNT revela a robustez inerente da sua agregação baseada em transformadores.

Como trabalhos futuros, pretende-se: (i) completar a avaliação sobre as 8 cenas

do LLFF, incluindo o regime *per-scene* com 100% das vistas; (ii) investigar a integração de estratégias de regularização geométrica (e.g., *depth priors*) aos modelos generalizáveis para mitigar a degradação observada; e (iii) estender o protocolo para datasets com geometrias mais desafiadoras, como o DTU, avaliando a robustez das conclusões sob diferentes distribuições de cena.

Referências

- Adobe (2025). *Substance 3D Viewer (beta)*. Computer Software.
- Hedman, P., Srinivasan, P. P., Mildenhall, B., Barron, J. T., and Debevec, P. (2021). Baking neural radiance fields for real-time view synthesis.
- Heo, H., Kim, T., Lee, J., Lee, J., Kim, S., Kim, H., and Kim, J.-H. (2023). Robust camera pose refinement for multi-resolution hash encoding.
- Kerbl, B., Kopanas, G., Leimkühler, T., and Drettakis, G. (2023). 3d gaussian splatting for real-time radiance field rendering. *ACM Transactions on Graphics*, 42(4).
- Kulhanek, J. and Sattler, T. (2025). Nerfbaselines: Consistent and reproducible evaluation of novel view synthesis methods.
- Mildenhall, B., Srinivasan, P. P., Ortiz-Cayon, R., Kalantari, N. K., Ramamoorthi, R., Ng, R., and Kar, A. (2019). Local light field fusion: Practical view synthesis with prescriptive sampling guidelines.
- Mildenhall, B., Srinivasan, P. P., Tancik, M., Barron, J. T., Ramamoorthi, R., and Ng, R. (2020). Nerf: Representing scenes as neural radiance fields for view synthesis.
- Müller, T. (2021). tiny-cuda-nn. <https://github.com/NVlabs/tiny-cuda-nn>. Version 1.7, BSD-3-Clause License.
- Müller, T., Evans, A., Schied, C., and Keller, A. (2022). Instant neural graphics primitives with a multiresolution hash encoding. *ACM Transactions on Graphics*, 41(4):1–15.
- Niemeyer, M., Barron, J. T., Mildenhall, B., Sajjadi, M. S., Geiger, A., and Radwan, N. (2022). Regnerf: Regularizing neural radiance fields for view synthesis from sparse inputs. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 5480–5490.
- Schwarz, K., Liao, Y., Niemeyer, M., and Geiger, A. (2021). Graf: Generative radiance fields for 3d-aware image synthesis.
- Tancik, M., Weber, E., Ng, E., Li, R., Yi, B., Wang, T., Kristoffersen, A., Austin, J., Salahi, K., Ahuja, A., Mcallister, D., Kerr, J., and Kanazawa, A. (2023). Nerfstudio: A modular framework for neural radiance field development. In *Special Interest Group on Computer Graphics and Interactive Techniques Conference Conference Proceedings, SIGGRAPH '23*, page 1–12. ACM.
- Wang, Z., Bovik, A. C., Sheikh, H. R., and Simoncelli, E. P. (2004). Image quality assessment: from error visibility to structural similarity. *IEEE transactions on image processing*, 13(4):600–612.
- Wang, Z., Varma, M., Wang, P., Chen, X., Chen, T., and Venugopalan, S. (2023). Is attention all that nerf needs?
- Wu, H., Xiao, B., Codella, N., Liu, M., Dai, X., Yuan, L., and Zhang, L. (2021). Cvt: Introducing convolutions to vision transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 22–31.
- Xue, Y., Ye, J., Zhou, Q., Long, L. R., Antani, S., Xue, Z., Cornwell, C., Zaino, R., Cheng, K. C., and Huang, X. (2021). Selective synthetic augmentation with histogan for improved histopathology image classification. *Medical Image Analysis*, 67:101816.

Yu, A., Ye, V., Tancik, M., and Kanazawa, A. (2021). pixelnerf: Neural radiance fields from one or few images.

Zhang, R., Isola, P., Efros, A. A., Shechtman, E., and Wang, O. (2018). The unreasonable effectiveness of deep features as a perceptual metric. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 586–595.