

# Uma Análise Comparativa entre NeRFs Few-Shot e Per-Scene aplicadas em Conjuntos de Dados de Vistas Esparsas

Felipe G. da Silva<sup>1</sup>

<sup>1</sup>Departamento de Ciências da Computação e Estatística – UNESP  
CEP: 15054-000 – São José do Rio Preto – SP – Brazil

`felipe-gomes.silva@unesp.br`

**Abstract.** *This work compares hybrid Generalizable NeRFs and Fast Optimization Per-Scene trained models applied to sparse-view datasets, evaluating the impact of these feature extraction architectures on novel view synthesis performance. Through a quantitative analysis using visual fidelity (PSNR, SSIM, LPIPS) and computational efficiency metrics (convergence time, VRAM footprint, inference time), this study highlights the trade-offs between the global generalization of Transformers and the local processing efficiency of convolutions. Ultimately, it aims to guide the selection of 3D rendering models for practical scenarios often constrained by hardware limitations and data scarcity.*

**Resumo.** *Esse trabalho apresenta uma comparação entre modelos generalizáveis via extratores de características e modelos de otimização rápida por cena aplicados em conjuntos de dados com vistas esparsas e avalia o impacto dessas arquiteturas de extração de características no desempenho em síntese de novas vistas. Por meio de uma análise quantitativa baseada em métricas de fidelidade visual (PSNR, SSIM e LPIPS) e de eficiência computacional (tempo de convergência, consumo de VRAM e tempo de inferência), o estudo busca quantificar os trade-offs entre a capacidade de generalização global dos Transformers e a eficiência de processamento local das convoluções, estabelecendo diretrizes empíricas para a seleção de modelos NeRF em regimes de dados escassos.*

## 1. Introdução

Modelos de campos de radiância neural (NeRF) consolidaram-se, nos anos recentes, como o estado da arte, tanto na indústria, quanto na academia, sobre geração de novas vistas [Kerbl et al. 2023, Tancik et al. 2023, Adobe 2025]. Entretanto, as mais avançadas técnicas de renderização neural exigem uma grande quantidade de: (i) poder computacional; (ii) múltiplas vistas no conjunto de dados. Ambos os desafios tendem a impedir que aplicações mais simples, como escaneamento *mobile* de objetos, provador virtual, geração de assets 3D e síntese em datasets pequenos, sejam aproveitados. É com tal problemática que projetos como Instant-NGP (*Instant Neural Graphics Primitives*), Nerfacto, Pixel-Nerf, Gnt (*Generalizable Nerf Transformer*) [Müller et al. 2022, Tancik et al. 2023, Yu et al. 2021, Wang et al. 2023], entre outros, tentam expandir o estado da arte e, consequentemente, abordam temas análogos, como: (i) *encoding* espacial de parâmetros [Müller et al. 2022]; (ii) uso de arquiteturas híbridas entre Convolutional Neural Networks (CNN) e Vision Transformers (ViT) [Schwarz et al. 2021, Wu et al. 2021, Wang et al. 2023]; e (iii) pré-computação (*baking*) dos modelos em estruturas de menor pegada de memória [Hedman et al. 2021].

Este trabalho tem, portanto, o objetivo de explorar o uso dos diferentes modelos de campos de radiância neural e suas respectivas técnicas de otimização, ao aplicá-las em conjuntos de dados com vistas esparsas, promovendo uma análise exploratória entre desempenho computacional e qualidade dos volumes gerados. Para avaliar a fidelidade das reconstruções, serão utilizadas métricas de qualidade visual amplamente consagradas na literatura, como PSNR (*Peak Signal-to-Noise Ratio*), SSIM (*Structural Similarity Index Measure*) [Wang et al. 2004] e LPIPS (*Learned Perceptual Image Patch Similarity*) [Zhang et al. 2018]. Paralelamente, a quantificação do custo operacional basear-se-á em métricas de desempenho sistêmico, incluindo o tempo de convergência no treinamento, a velocidade de inferência e a pegada de memória (*memory footprint*), sobretudo o consumo de VRAM (*Video Random Access Memory*). Embora trabalhos como [Niemeyer et al. 2022] e [Heo et al. 2023] tenham avaliado NeRFs em regimes de dados limitados, a comparação sistemática entre modelos generalizáveis com extratores convolucionais versus baseados em atenção, sob condições controladas de hardware e splits reprodutíveis, permanece pouco explorada na literatura. Em suma, esta investigação fornece um panorama consolidado sobre os *trade-offs* entre eficiência computacional e fidelidade visual, estabelecendo diretrizes claras para a viabilização e aplicação prática de modelos de síntese de novas vistas em cenários com restrições das mais diversas, especialmente de dados e de hardware.

As contribuições deste trabalho são: (i) uma avaliação sistemática e reprodutível de modelos NeRF few-shot e per-scene sob três regimes de dados; (ii) a integração nativa de PixelNeRF e GNT ao framework Nerfstudio, disponibilizada publicamente em <https://github.com/felipe-gsilva/few-shot-nerfs>, permitindo que experimentos sejam reproduzidos sob protocolo unificado.

## 2. Fundamentação Teórica

### 2.1. Conjuntos de Dados de Vistas Esparsas

Essa nomenclatura refere-se, neste trabalho, aos conjuntos de dados imagéticos que possuem pouca (ou nenhuma) redundância e/ou variabilidade de diferentes poses de câmera referentes ao mesmo objeto. Áreas como histologia, holotomografia e microscopia confocal de fluorescência ilustram bem esse problema: a aquisição de imagens multi-vista é fisicamente limitada, biologicamente invasiva e estruturalmente esparsa por natureza [Xue et al. 2021].

### 2.2. Campos de Radiância Neural

Campos de Radiância Neural (*Neural Radiance Fields*, NeRF) utilizam-se de redes neurais do tipo MLP (*Multilayer Perceptron*) para aproximar uma função contínua no espaço 5D. Essa função recebe como entrada uma posição espacial  $\mathbf{x} = (x, y, z)$  e uma direção de visualização  $\mathbf{d} = (\theta, \phi)$ , retornando a densidade volumétrica  $\sigma(\mathbf{x})$  e a cor associada  $\mathbf{c} = (r, g, b)$ :

$$F_{\theta} : F_{\theta} \circ \gamma(\mathbf{x}, \mathbf{d}) \rightarrow (\sigma, \mathbf{c}), \quad \sigma \in \mathbb{R}_{\geq 0}, \quad \mathbf{c} \in [0, 1]^3$$

onde  $\theta$  representa os pesos da rede neural e  $\gamma$  um codificador posicional.

### 2.3. Representações de Cena

Trabalhos subsequentes introduziram representações híbridas que desacoplam a estrutura espacial da rede neural, dado a viabilidade de alterar-se o *positional encoding* via codificação de fourier por um sistema de *hash encoding*. O Instant-NGP [Müller et al. 2022] propõe uma codificação por tabela de hash multiescala, que mapeia coordenadas espaciais em vetores de características de forma eficiente, reduzindo drasticamente o tempo de otimização por cena. O Nerfacto [Tancik et al. 2023] estende essa ideia combinando múltiplas otimizações comprovadas da literatura focando no equilíbrio entre qualidade visual e tempo de renderização em tempo real.

### 2.4. Renderização Volumétrica

Seja um campo de radiância neural  $F_\theta$ , a cor esperada de um pixel é computada através de renderização volumétrica. Dado um raio  $\mathbf{r}(t) = \mathbf{o} + t\mathbf{d}$  com limites de profundidade  $(t_n, t_f)$ , a cor resultante é dada pela integral:

$$\hat{C}(\mathbf{r}) = \int_{t_n}^{t_f} T(t) \sigma(\mathbf{r}(t)) \mathbf{c}(\mathbf{r}(t), \mathbf{d}) dt$$

onde  $T(t) = \exp\left(-\int_{t_n}^t \sigma(\mathbf{r}(s)) ds\right)$  denota a transmitância acumulada ao longo do raio, ou seja, a probabilidade de o raio não atingir nenhuma partícula obstrutiva até a profundidade  $t$ . Na prática, por ser uma função contínua, essa integral é aproximada numericamente via *alpha compositing* sobre amostras discretas interpoladas ao longo de cada raio durante o treinamento.

### 2.5. Extrator de Características

O extrator de características se torna, portanto, responsável por codificar as imagens de entrada em representações que a rede neural possa condicionar. O PixelNeRF [Yu et al. 2021] utiliza uma ResNet (*Residual Neural Network*) pré-treinada para extrair mapas de características por imagem; dado um ponto 3D, sua projeção nas vistas de entrada recupera os vetores de características espaciais correspondentes, que são agregados e passados à MLP de radiância. Essa abordagem é local e opera por pixel, sem modelar explicitamente relações entre vistas. O GNT (Generalizable NeRF Transformer) [Wang et al. 2023] substitui: (i) o extrator de características por um *transformer* capaz de utilizar de mecanismos de atenção para angariar características mais globais ao objeto; (ii) a MLP de radiância também por um *transformer* que amostra pontos ao longo do raio e agrega informação entre vistas por meio de atenção cruzada, eliminando a dependência de uma função de volume explícita.

### 2.6. NeRFs Few-Shot vs. Per-Scene

Com o objetivo de reduzir a necessidade de múltiplas vistas durante o treinamento, surgiram abordagens conhecidas como NeRFs *few-shot*, capazes de generalizar a cena e produzir novas vistas a partir de poucas imagens, utilizando-se de diversos conceitos distintos aplicados aos componentes NeRF supracitados. Estas abordagens contrastam frontalmente com os métodos *per-scene*. Enquanto modelos *per-scene* (como Instant-NGP) otimizam uma estrutura de dados de forma isolada e colapsam sob a escassez de vistas, arquiteturas *few-shot* e generalizáveis incorporam *priors* estruturais e semânticos aprendidos de grandes bases de dados. Essa distinção arquitetural torna-se indispensável em cenários onde a extração é severamente restrita.

### 3. Metodologia

Esta seção contempla a metodologia adotada para a realização dos experimentos, incluindo a descrição dos conjuntos de dados utilizados, os modelos de NeRF selecionados para o estudo comparativo, as métricas de avaliação aplicadas e o ambiente computacional onde os testes foram conduzidos. A metodologia foi conduzida baseando-se em 3 regimes distintos:

- *Per-Scene*: os modelos *per-scene* foram treinados com 100% do conjunto de dados, passando por um grande tempo de treino se comparado aos outros modelos.
- *Test-Time Adaptation (TTA)*: de 3 a 10 imagens alimentaram os modelos *few-shot*, uma técnica de fine tuning comum na literatura, permitindo melhor adaptação à cena.
- *Zero-Shot*: Para testar a capacidade de generalização dos modelos *few-shot*, utilizou-se um regime de nenhuma imagem nova de treino, apenas com os pesos pré-carregados e as imagens em tempo de teste inseridas.

Para viabilizar a comparação entre os modelos, implementou-se, individualmente, (caso não houvesse presença prévia) a integração do modelo proposto com a ferramenta NeRFStudio. A seguir, apresentam-se os modelos selecionados.

#### 3.1. Modelos Selecionados

Neste trabalho, são avaliados modelos representativos para reconstrução de campos de radiância neural em cenários de poucas vistas (*few-shot*), contemplando diferentes paradigmas arquiteturais e estratégias de aprendizado. Especificamente, consideram-se:

1. PixelNeRF [Yu et al. 2021], que utiliza redes neurais convolucionais para extrair características espaciais das imagens e inseri-las no renderizador através de interpolação e projeção;
2. Generalizable NeRF Transformer (GNT) [Wang et al. 2023], que emprega mecanismos de atenção (*Transformers*) em ambos os componentes NeRF, substituindo tanto o extrator de características quanto o renderizador diferenciável por módulos baseados em atenção cruzada;

Para fins de linha de base (baseline) comparativa, este estudo também avalia métodos *per-scene* sob regime de dados limitados:

1. Instant-NGP [Müller et al. 2022], que substitui a MLP tradicional por uma codificação em tabela de hash multiescala, permitindo otimização por cena em tempo significativamente reduzido; e
2. Nerfacto [Tancik et al. 2023], modelo focado em eficiência que agrega as melhores heurísticas da literatura para proporcionar alta qualidade e treinamento rápido.

A fim de justificar a seleção das linhas de base, ressalta-se a ausência de outras arquiteturas seminais no protocolo de avaliação. A restrição aos modelos selecionados visa manter o foco no contraste metodológico entre abordagens generalizáveis (via extração de características) e estruturas explícitas otimizadas por cena, evitando a explosão combinatória do estudo. A seguir, detalham-se as motivações técnicas para a exclusão de arquiteturas proeminentes:

- **RegNeRF:** Embora seja o estado da arte em cenários de poucas vistas, sua premissa central baseia-se na aplicação de *priors* geométricos e na regularização de semântica e profundidade em poses não observadas, frequentemente utilizando fluxos normalizadores (*normalizing flows*). Como o escopo deste trabalho reside em avaliar a capacidade intrínseca de generalização dos extratores de características (CNNs vs. Transformadores) e a eficiência estrutural de representações por *hash*, a inclusão de um método fortemente baseado em regularização de otimização desviaria o foco analítico.
- **MVSNeRF:** Apesar de ser um modelo generalizável robusto, sua arquitetura fundamenta-se na construção de volumes de custo 3D (*cost volumes*) baseados em princípios de *Multi-View Stereo* (MVS). Esta formulação impõe uma dinâmica de uso de memória e um paradigma de reconstrução geométrica que diferem substancialmente da codificação direta por projeção 2D (PixelNeRF) ou da agregação puramente atencional (GNT), inviabilizando uma comparação direta (*apples-to-apples*) no que tange ao *footprint* de VRAM.
- **Mip-NeRF 360:** Projetado especificamente para mitigar o problema de aliasing e parametrizar o espaço de forma não linear em cenas abertas e irrestritas (*unbounded 360-degree*). Dado que o protocolo experimental deste estudo adota o dataset LLFF, caracterizado majoritariamente por capturas frontais de profundidade delimitada (*forward-facing*), a principal contribuição do Mip-NeRF 360 torna-se mecanicamente subutilizada. Ademais, sem acoplamento a estratégias de regularização *few-shot*, o modelo sofre degradação análoga aos métodos *per-scene* já representados de forma mais eficiente pelo Instant-NGP e Nerfacto.

A seleção e exclusão dos modelos supracitados visa proporcionar uma análise abrangente entre diferentes abordagens, cobrindo métodos baseados em CNNs, transformadores, reconstrução volumétrica explícita e modelos generativos baseados em representações por *hash per-scene*. Essa diversidade permite avaliar a qualidade de reconstrução em cenários com vistas limitadas e o compromisso entre generalização e custo computacional, bem como o impacto de estratégias distintas nos três regimes de avaliação considerados, como observado na seção 3.3.

### 3.2. Implementação no Nerfstudio

Os modelos foram implementados no framework *Nerfstudio* [Tancik et al. 2023], seguindo sua arquitetura modular. As adaptações concentraram-se nos componentes *DataManager* e *Pipeline*, responsáveis pelo carregamento das vistas de entrada e pela agregação das características multi-vista, respectivamente, mantendo inalterados os módulos de renderização e avaliação nativos do framework. A adoção de um framework unificado assegura equivalência no protocolo de avaliação entre os modelos, eliminando variáveis de implementação que poderiam comprometer a comparação, visto que o *Nerfstudio* oferece, ademais, um conjunto de utilitários aproveitados neste trabalho:

1. visualização em tempo real por meio de interface gráfica interativa, permitindo monitorar o treinamento e inspecionar qualitativamente os resultados de renderização durante o processo;
2. aceleração via GPU com suporte a CUDA, integrada à biblioteca *tiny-cuda-nn* [Müller 2021], que fornece implementações otimizadas de MLPs e codificações de entrada diretamente em kernels CUDA, com ganho de desempenho reportado

entre  $5\times$  e  $30\times$  em relação a implementações PyTorch convencionais, dependendo da arquitetura e do cenário de uso; e

3. infraestrutura de logging e exportação de métricas, incluindo salvamento de checkpoints e integração com *Weights & Biases*, que padroniza o registro dos experimentos entre os diferentes modelos.

Dentre os modelos avaliados, o Instant-NGP e o Nerfacto encontram-se nativamente integrados ao *Nerfstudio*, dispensando adaptações de implementação. Os demais modelos (PixelNeRF e GNT) foram portados para o framework a partir de suas implementações originais, com adaptações nos componentes de *DataManager*, *Pipeline* e *model* para conformidade com a interface do *Nerfstudio*, ambos utilizando-se do otimizador Adam (otimizado pelo tinycudann) com *learning rate*  $\eta = 1^{-3}$  e *weight decay* = 0.0.

As implementações foram guiadas pelas descrições metodológicas dos trabalhos originais, mantendo equivalência funcional. A implementação completa encontra-se disponível em <https://github.com/felipe-gsilva/few-shot-nerfs>.

### 3.3. Protocolo Experimental

Os experimentos foram conduzidos sobre o dataset LLFF (*Local Light Field Fusion*) [Mildenhall et al. 2019], composto por cenas de objetos reais capturadas com câmera em movimento frontal. A adoção do LLFF decorre de sua compatibilidade com o protocolo de avaliação estabelecido por Niemeyer et al. [RegNeRF], da disponibilidade pública dos splits reproduzíveis e da viabilidade de execução em hardware com 6 GB de VRAM, condição que inviabiliza o processamento dos volumes de custo tridimensionais exigidos pelo DTU na resolução original. Seguindo, ademais, o protocolo estabelecido por [Niemeyer et al. 2022] no RegNeRF, reservam-se para teste as imagens cujo índice é múltiplo de 8 (lfffhold=8), totalizando entre 5 e 8 imagens de teste por cena. As  $N$  vistas de treinamento ( $N \in 3, 6, 10$ ) são amostradas uniformemente das imagens remanescentes.

A seleção das vistas de treino foi realizada por duas estratégias distintas: (i) *uniform*, em que as vistas são amostradas por interpolação linear sobre os índices do dataset, distribuindo-as uniformemente ao longo da trajetória da câmera; e (ii) *random*, em que as vistas são sorteadas aleatoriamente com semente fixa, garantindo reprodutibilidade. A comparação entre as duas estratégias permite avaliar a sensibilidade dos modelos à distribuição espacial das vistas de entrada.

A Tabela 1 reporta o impacto da estratégia de amostragem das vistas de treino sobre o desempenho médio no conjunto de teste, para o regime TTA com  $N = 10$  vistas.

As imagens restantes foram divididas proporcionalmente entre conjuntos de validação e teste, também com semente fixa, assegurando que as vistas de teste sejam idênticas entre todos os modelos e estratégias de split, eliminando variáveis de avaliação que poderiam comprometer a comparação. As métricas finais são reportadas exclusivamente sobre o conjunto de teste, sem sobreposição com as vistas de treino. Todos os experimentos foram executados em uma GPU NVIDIA GeForce GTX 1660 Super (6GB de VRAM), com CUDA 12.4 e driver 610.43.02. Para garantir reprodutibilidade em diferentes arquiteturas, optou-se por utilizar a ferramenta docker, a qual permite instanciar a GPU virtualmente e viabilizar o uso do torch, tiny-cuda-nn e cuda 12.4 entre diferentes arquiteturas de GPU (testado apenas em arquiteturas NVIDIA).

**Tabela 1. Impacto da estratégia de seleção de vistas de treino (*uniform* vs. *random*) sobre a qualidade visual média no dataset LLFF, avaliado no regime TTA com  $N = 10$  vistas. Resultados reportados como média sobre as 8 cenas do dataset.**

| Modelo      | Split   | PSNR (dB) $\uparrow$ | SSIM $\uparrow$ | LPIPS $\downarrow$ | $\Delta$ PSNR ( <i>unif. – rand.</i> ) |
|-------------|---------|----------------------|-----------------|--------------------|----------------------------------------|
| PixelNeRF   | Uniform | 5.70                 | 0.089           | 0.837              | –                                      |
|             | Random  | –                    | –               | –                  |                                        |
| GNT         | Uniform | 10.33                | 0.289           | 0.732              | –                                      |
|             | Random  | –                    | –               | –                  |                                        |
| Instant-NGP | Uniform | 13.57                | 0.440           | 0.507              | –                                      |
|             | Random  | –                    | –               | –                  |                                        |
| Nerfacto    | Uniform | 26.25                | 0.843           | 0.205              | –                                      |
|             | Random  | –                    | –               | –                  |                                        |

### 3.4. Métricas de Avaliação


A avaliação dos modelos contempla três dimensões complementares: qualidade visual, eficiência computacional e pegada de memória.

Para a qualidade visual, são empregadas três métricas amplamente adotadas na literatura de síntese de novas vistas: (i) PSNR (*Peak Signal-to-Noise Ratio*), que mede a fidelidade pixel a pixel entre a imagem renderizada e a imagem de referência em escala logarítmica, sendo sensível a erros de brilho e cor; (ii) SSIM (*Structural Similarity Index Measure*) [Wang et al. 2004], que avalia a similaridade estrutural entre imagens considerando luminância, contraste e estrutura, sendo mais correlacionado com a percepção humana do que o PSNR; e (iii) LPIPS (*Learned Perceptual Image Patch Similarity*) [Zhang et al. 2018] usando a rede VGG (Visual Geometry Group) como extrator de características, seguindo o protocolo de [Niemeyer et al. 2022] para quantificar a distância perceptual entre imagens (valores menores indicam maior similaridade perceptual). Para a eficiência computacional, é medida a taxa de renderização em quadros por segundo (*fps*), avaliada durante a inferência sobre as câmeras do conjunto de teste. Para a pegada de memória, é reportado o footprint de parâmetros do modelo, calculado como a soma do produto entre o número de parâmetros e o tamanho de cada elemento em bytes. Também comparou-se os respectivos tamanhos de parâmetros com a quantidade de memória alocada no torch naquele dado momento. Como o ambiente de GPU é controlado (reservado pelo ambiente docker), possíveis outros processos simultâneos não adicionaram ruído às métricas de avaliação.

As avaliações de qualidade visual são realizadas sobre o conjunto de teste gerado pelo protocolo de split descrito na Seção 3.3, utilizando o *dataloader* de avaliação do *Nerfstudio* (`fixed_indices_eval_dataloader`), que itera sobre câmeras fixas e compara as imagens renderizadas (`outputs["rgb"]`) com as imagens de referência (`batch["image"]`) sem amostras das vistas de treino.

## 4. Experimentos e Resultados

A seguir, destacam-se os principais resultados do treinamento, que levou, ao todo, cerca de 90 horas para ser completado. A Figura 1 ilustra o protocolo de execução adotado. Segmenta-se esta seção entre uma análise quantitativa, qualitativa e computacional, respectivamente.



**Figura 1. Protocolo de execução experimental.** As caixas superiores representam as etapas do pipeline; as ramificações inferiores detalham as variantes de configuração (estratégia de split, regime de treino) e as métricas coletadas. Todo o ambiente foi isolado via contêiner Docker com GPU reservada.

### 4.1. Análise Quantitativa

A análise quantitativa seguiu o protocolo experimental supracitados, comparando as métricas LPIPS, SIM e PSNR (Seção 3.4) entre todos os modelo e regimes de treino (Seção 3). A Tabela 2 apresenta as métricas escolhidas:

Como referência externa, a Tabela 3 compila resultados reportados pelo *Nerf-Baselines* [Kulhanek and Sattler 2025] para o LLFF — um dataset predominantemente *forward-facing*, para o qual métodos NeRF costumam empregar parametrização em espaço NDC. Estes números são apresentados apenas como comparativo de literatura (protocolo/hardware podem divergir do presente estudo).

A Tabela 4 desagrega o PSNR por cena individual do LLFF, revelando a variabilidade de desempenho em função das características estruturais de cada cena.

### 4.2. Análise Qualitativa

A análise qualitativa seguiu as estruturas do split (3.3), sendo possíveis renderizações do volume em projeções tanto ortográficas quanto perspectivas. Para facilitar a identificação visual, optou-se por utilizar o acúmulo dos raios em projeção perspectiva, requerindo à rede tanto vistas já conhecidas (com os dados de câmera existentes) quanto novas vistas (o objeto de estudo deste trabalho). Destaca-se, a seguir, os principais resultados visuais:

Ground Truth      Pixel-NeRF      GNT      Instant-NGP      Nerfacto

**Figura 2. Comparação qualitativa no regime TTA (10 vistas) para a cena "Trex" do dataset LLFF.** Destaca-se a perda de detalhes de alta frequência nos modelos generativos (PixelNeRF, GNT) em oposição aos ruídos de geometria apresentados pelos modelos per-scene (Instant-NGP, Nerfacto) sob escassez de dados.

Tabela 2. Avaliação quantitativa da qualidade visual no dataset LLFF. As setas indicam se valores maiores ( $\uparrow$ ) ou menores ( $\downarrow$ ) representam desempenho superior. Negrito indica o melhor resultado dentro de cada regime; sublinhado indica o segundo melhor.

| Regime           | Modelo      | PSNR (dB) $\uparrow$ | SSIM $\uparrow$ | LPIPS $\downarrow$ |
|------------------|-------------|----------------------|-----------------|--------------------|
| Zero-Shot        | PixelNeRF   | 5.81                 | 0.088           | 0.833              |
|                  | GNT         | <b>10.33</b>         | <b>0.289</b>    | <b>0.732</b>       |
| TTA ( $N = 3$ )  | PixelNeRF   | 5.69                 | 0.073           | 0.823              |
|                  | GNT         | 10.33                | 0.289           | 0.732              |
|                  | Instant-NGP | <u>13.61</u>         | <u>0.439</u>    | <u>0.506</u>       |
|                  | Nerfacto    | <b>26.25</b>         | <b>0.843</b>    | <b>0.205</b>       |
| TTA ( $N = 6$ )  | PixelNeRF   | 6.05                 | 0.103           | 0.829              |
|                  | GNT         | 10.19                | 0.290           | 0.732              |
|                  | Instant-NGP | <u>13.61</u>         | <u>0.439</u>    | <u>0.506</u>       |
|                  | Nerfacto    | <b>26.25</b>         | <b>0.843</b>    | <b>0.205</b>       |
| TTA ( $N = 10$ ) | PixelNeRF   | 5.70                 | 0.089           | 0.837              |
|                  | GNT         | 10.33                | 0.289           | 0.732              |
|                  | Instant-NGP | <u>13.57</u>         | <u>0.440</u>    | <u>0.507</u>       |
|                  | Nerfacto    | <b>26.25</b>         | <b>0.843</b>    | <b>0.205</b>       |
| Per-Scene (100%) | Instant-NGP | —                    | —               | —                  |
|                  | Nerfacto    | —                    | —               | —                  |

Figura 3. Trade-off entre Fidelidade Visual (PSNR) e Consumo de VRAM no regime de 10 vistas. O quadrante superior esquerdo representa a região ideal (alta qualidade, baixo custo).

#### 4.3. Trade-offs Computacionais

### 5. Conclusões

Este trabalho apresentou uma análise comparativa entre modelos NeRF generalizáveis (PixelNeRF, GNT) e modelos de otimização por cena (Instant-NGP, Nerfacto) em regimes de vistas esparsas, sob protocolo unificado no framework Nerfstudio. Os resultados parciais obtidos sobre o dataset LLFF revelam tendências que, embora preliminares, permitem delinear conclusões relevantes sobre os *trade-offs* entre fidelidade visual e custo computacional.

No eixo de qualidade visual, os dados evidenciam uma hierarquia consistente entre os modelos avaliados. O Nerfacto alcançou o melhor desempenho em todos os regimes TTA, com PSNR de 26,25 dB, SSIM de 0,843 e LPIPS de 0,205, seguido pelo Instant-NGP (PSNR  $\approx$  13,6 dB). Os modelos generalizáveis apresentaram desempenho substancialmente inferior: o GNT atingiu PSNR de 10,33 dB e o PixelNeRF permaneceu abaixo

**Tabela 3. Resultados no LLFF reportados pelo *NerfBaselines* [Kulhanek and Sattler 2025]. "Time" refere-se ao tempo total de treinamento reportado e "GPU mem." ao pico de memória alocada durante o treino.**

| Método       | PSNR (dB) $\uparrow$ | SSIM $\uparrow$ | LPIPS (VGG) $\downarrow$ | Time       | GPU mem. (GB) |
|--------------|----------------------|-----------------|--------------------------|------------|---------------|
| Mip-NeRF 360 | 26.59                | 0.846           | 0.168                    | 9h 55m 23s | 104.98        |
| TensoRF      | 26.68                | 0.834           | 0.202                    | 31m 32s    | 20.38         |

**Tabela 4. Análise de desempenho por cena do dataset LLFF (PSNR em dB), regime TTA com  $N = 10$  vistas, split *uniform*. A última coluna reporta o desvio padrão entre cenas ( $\sigma$ ), indicando a estabilidade de cada modelo frente à variabilidade do conteúdo visual.**

| Modelo      | <i>fern</i> | <i>flower</i> | <i>fortress</i> | <i>horns</i> | <i>leaves</i> | <i>orchids</i> | <i>room</i> | <i>trex</i> | Média | $\sigma$ |
|-------------|-------------|---------------|-----------------|--------------|---------------|----------------|-------------|-------------|-------|----------|
| PixelNeRF   | 5.70        | —             | —               | —            | —             | —              | —           | —           | —     | —        |
| GNT         | 10.33       | —             | —               | —            | —             | —              | —           | —           | —     | —        |
| Instant-NGP | 13.57       | —             | —               | —            | —             | —              | —           | —           | —     | —        |
| Nerfacto    | 26.25       | —             | —               | —            | —             | —              | —           | —           | —     | —        |

de 6,1 dB em todas as configurações. A superioridade dos métodos *per-scene* mesmo sob escassez extrema de vistas (3 imagens) sugere que, para cenas do tipo *forward-facing* com geometria moderadamente complexa, a capacidade de otimização direta da representação espacial — viabilizada por codificações eficientes como tabelas de hash multiescala — compensa a ausência de *priors* aprendidos.

Contudo, a análise computacional revela um *trade-off* não trivial. Os modelos generalizáveis dispensam otimização por cena no regime *zero-shot* e requerem adaptação mínima no TTA (8 s para PixelNeRF;  $\sim 7$  min para GNT), enquanto os modelos *per-scene* demandam tempos de convergência significativamente maiores ( $\sim 13$  min para Nerfacto;  $\sim 38$  min para Instant-NGP com 10 vistas). Em contrapartida, os modelos *per-scene* apresentaram taxas de inferência superiores (0,41 FPS para Nerfacto vs. 0,006 FPS para PixelNeRF), com menor consumo de VRAM (1,29 GB vs. 1,93 GB). Esses resultados indicam que, em cenários onde a latência de inferência e o *footprint* de memória são críticos — como aplicações *mobile* ou sistemas embarcados —, os métodos *per-scene* podem ser preferíveis mesmo com o custo adicional de treinamento.

É necessário ressaltar que os resultados reportados são parciais, restritos à cena *fern* do LLFF, e a generalização para o conjunto completo de 8 cenas requer execuções adicionais. O desempenho excepcionalmente baixo do PixelNeRF ( $< 6$  dB) indica possíveis incompatibilidades na adaptação dos pesos pré-treinados ao pipeline do Nerfstudio, aspecto que será investigado em trabalhos futuros. Além disso, a estabilidade das métricas do Nerfacto entre os regimes de 3, 6 e 10 vistas demanda verificação quanto à independência efetiva dos *checkpoints* entre configurações.

Como trabalhos futuros, pretende-se: (i) completar a avaliação sobre as 8 cenas do LLFF, incluindo o regime *per-scene* com 100% das vistas e o split *random*; (ii) investigar a integração de estratégias de regularização geométrica (e.g., *depth priors*) aos modelos generalizáveis para mitigar a degradação observada; e (iii) estender o protocolo

**Tabela 5. Comparativo de custo computacional e pegada de memória. O tempo de treinamento refere-se à convergência da cena (ou adaptação no caso TTA), e a VRAM indica o pico de alocação durante o treinamento. A taxa de FPS foi medida na renderização do conjunto de teste.**

| <b>Modelo</b> | <b>Regime</b> | <b>Tempo de Treino</b> | <b>Pico VRAM (GB)</b> | <b>Inferência (FPS)</b> |
|---------------|---------------|------------------------|-----------------------|-------------------------|
| PixelNeRF     | Zero-Shot (0) | N/A (Pré-treinado)     | 1.93                  | 0.006                   |
| GNT           | Zero-Shot (0) | N/A (Pré-treinado)     | 1.93                  | 0.008                   |
| PixelNeRF     | TTA (10)      | 00 min 08 s            | 1.93                  | 0.006                   |
| GNT           | TTA (10)      | 06 min 55 s            | 1.93                  | 0.008                   |
| Instant-NGP   | TTA (10)      | 37 min 45 s            | 1.29                  | 0.241                   |
| Nerfacto      | TTA (10)      | 13 min 11 s            | 1.29                  | 0.408                   |
| Instant-NGP   | Per-Scene     | –                      | –                     | –                       |
| Nerfacto      | Per-Scene     | –                      | –                     | –                       |

para datasets com geometrias mais desafiadoras, como o DTU, avaliando a robustez das conclusões sob diferentes distribuições de cena.

## Referências

- Adobe (2025). *Substance 3D Viewer (beta)*. Computer Software.
- Hedman, P., Srinivasan, P. P., Mildenhall, B., Barron, J. T., and Debevec, P. (2021). Baking neural radiance fields for real-time view synthesis.
- Heo, H., Kim, T., Lee, J., Lee, J., Kim, S., Kim, H., and Kim, J.-H. (2023). Robust camera pose refinement for multi-resolution hash encoding.
- Kerbl, B., Kopanas, G., Leimkühler, T., and Drettakis, G. (2023). 3d gaussian splatting for real-time radiance field rendering. *ACM Transactions on Graphics*, 42(4).
- Kulhanek, J. and Sattler, T. (2025). Nerfbaselines: Consistent and reproducible evaluation of novel view synthesis methods.
- Mildenhall, B., Srinivasan, P. P., Ortiz-Cayon, R., Kalantari, N. K., Ramamoorthi, R., Ng, R., and Kar, A. (2019). Local light field fusion: Practical view synthesis with prescriptive sampling guidelines.
- Müller, T. (2021). `tiny-cuda-nn`. <https://github.com/NVlabs/tiny-cuda-nn>. Version 1.7, BSD-3-Clause License.
- Müller, T., Evans, A., Schied, C., and Keller, A. (2022). Instant neural graphics primitives with a multiresolution hash encoding. *ACM Transactions on Graphics*, 41(4):1–15.
- Niemeyer, M., Barron, J. T., Mildenhall, B., Sajjadi, M. S., Geiger, A., and Radwan, N. (2022). Regnerf: Regularizing neural radiance fields for view synthesis from sparse inputs. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 5480–5490.
- Schwarz, K., Liao, Y., Niemeyer, M., and Geiger, A. (2021). Graf: Generative radiance fields for 3d-aware image synthesis.
- Tancik, M., Weber, E., Ng, E., Li, R., Yi, B., Wang, T., Kristoffersen, A., Austin, J., Salahi, K., Ahuja, A., Mcallister, D., Kerr, J., and Kanazawa, A. (2023). Nerfstudio: A modular framework for neural radiance field development. In *Special Interest Group on Computer Graphics and Interactive Techniques Conference Conference Proceedings, SIGGRAPH '23*, page 1–12. ACM.
- Wang, Z., Bovik, A. C., Sheikh, H. R., and Simoncelli, E. P. (2004). Image quality assessment: from error visibility to structural similarity. *IEEE transactions on image processing*, 13(4):600–612.
- Wang, Z., Varma, M., Wang, P., Chen, X., Chen, T., and Venugopalan, S. (2023). Is attention all that nerf needs?
- Wu, H., Xiao, B., Codella, N., Liu, M., Dai, X., Yuan, L., and Zhang, L. (2021). Cvt: Introducing convolutions to vision transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 22–31.
- Xue, Y., Ye, J., Zhou, Q., Long, L. R., Antani, S., Xue, Z., Cornwell, C., Zaino, R., Cheng, K. C., and Huang, X. (2021). Selective synthetic augmentation with histogan for improved histopathology image classification. *Medical Image Analysis*, 67:101816.
- Yu, A., Ye, V., Tancik, M., and Kanazawa, A. (2021). pixelnerf: Neural radiance fields from one or few images.

Zhang, R., Isola, P., Efros, A. A., Shechtman, E., and Wang, O. (2018). The unreasonable effectiveness of deep features as a perceptual metric. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 586–595.