

Uma Análise Comparativa entre NeRFs Few-Shot e Per-Scene aplicadas em Conjuntos de Dados de Vistas Esparsas

Felipe G. da Silva¹

¹Departamento de Ciências da Computação e Estatística – UNESP
CEP: 15054-000 – São José do Rio Preto – SP – Brazil

`felipe-gomes.silva@unesp.br`

Abstract. *This work compares Generalizable NeRFs and Fast Optimization Per-Scene trained models applied to sparse-view datasets, evaluating the impact of these feature extraction architectures on novel view synthesis performance. Through a quantitative analysis using visual fidelity (PSNR, SSIM, LPIPS) and computational efficiency metrics (convergence time, VRAM footprint, inference time), this study highlights the trade-offs between the global generalization of Transformers and the local processing efficiency of convolutions. Ultimately, it aims to guide the selection of 3D rendering models for practical scenarios often constrained by hardware limitations and data scarcity.*

Resumo. *Este trabalho apresenta uma análise comparativa entre modelos generalizáveis via extratores de características e modelos de otimização rápida por cena aplicados em conjuntos de dados com vistas esparsas, avaliando o impacto dessas arquiteturas no desempenho de síntese de novas vistas. Por meio de uma investigação quantitativa baseada em métricas de fidelidade visual (PSNR, SSIM e LPIPS) e de eficiência computacional (tempo de convergência, consumo de VRAM e tempo de inferência), o estudo quantifica os compromissos entre a capacidade de generalização global dos Transformers e a eficiência de processamento local das convoluções. O objetivo principal consiste em estabelecer diretrizes empíricas robustas para a seleção de modelos NeRF em cenários severamente limitados por escassez de dados e restrições práticas de hardware.*

1. Introdução

Modelos de campos de radiância neural (NeRF) consolidaram-se, nos anos recentes, como o estado da arte, tanto na indústria, quanto na academia, sobre geração de novas vistas [Kerbl et al. 2023, Tancik et al. 2023, Adobe 2025]. Entretanto, as mais avançadas técnicas de renderização neural demandam de enormes quantias de: (i) poder computacional; (ii) múltiplas vistas no conjunto de dados. Ambos os desafios inviabilizam aplicações práticas como escaneamento mobile, provedores virtuais e síntese em conjuntos de dados reduzidos. É com tal problemática que projetos como Instant-NGP (*Instant Neural Graphics Primitives*), Nerfacto, Pixel-Nerf, Gnt (*Generalizable Nerf Transformer*) [Müller et al. 2022, Tancik et al. 2023, Yu et al. 2021, Wang et al. 2023], entre outros, tentam expandir o estado da arte e, consequentemente, abordam temas análogos, como: (i) *encoding* espacial de parâmetros [Müller et al. 2022]; (ii) uso de arquiteturas híbridas entre Convolutional Neural Networks (CNN) e Vision Transformers (ViT)

[Schwarz et al. 2021, Wu et al. 2021, Wang et al. 2023]; e (iii) pré-computação (*baking*) dos modelos em estruturas de menor pegada de memória [Hedman et al. 2021].

Este trabalho tem, por conseguinte, o objetivo de explorar o uso dos diferentes modelos de campos de radiância neural e suas respectivas técnicas de otimização, ao aplicá-las em conjuntos de dados com vistas esparsas, promovendo uma análise exploratória entre desempenho computacional e qualidade dos volumes gerados. Para avaliar a fidelidade das reconstruções, serão utilizadas métricas de qualidade visual amplamente consagradas na literatura, como PSNR (*Peak Signal-to-Noise Ratio*), SSIM (*Structural Similarity Index Measure*) [Wang et al. 2004] e LPIPS (*Learned Perceptual Image Patch Similarity*) [Zhang et al. 2018]. Paralelamente, a quantificação do custo operacional basear-se-á em métricas de desempenho sistêmico, incluindo o tempo de convergência no treinamento, a velocidade de inferência e a pegada de memória (*memory footprint*), sobretudo o consumo de VRAM (*Video Random Access Memory*). Embora trabalhos como [Niemeyer et al. 2022] e [Heo et al. 2023] tenham avaliado NeRFs em regimes de dados limitados e trabalhos como NerfBaselines [Kulhanek and Sattler 2025] tenham constatado resultados em NeRFs tradicionais e baseados em treinamento por cena, a comparação sistemática entre modelos generalizáveis com extratores convolucionais versus baseados em atenção, sob condições controladas de hardware e splits reproduzíveis, permanece inexplorada na literatura. Em suma, esta investigação fornece um panorama consolidado sobre os *trade-offs* entre eficiência computacional e fidelidade visual, estabelecendo diretrizes claras para a viabilização e aplicação prática de modelos de síntese de novas vistas em cenários com restrições das mais diversas, especialmente de dados e de hardware.

Diante desta problemática, as contribuições deste trabalho são: (i) uma avaliação sistemática e reproduzível de modelos NeRF few-shot e per-scene sob três regimes de dados; (ii) a integração nativa de PixelNeRF e GNT ao framework Nerfstudio, disponibilizada publicamente em <https://github.com/felipe-gsilva/few-shot-nerfs>, permitindo que experimentos sejam reproduzidos sob protocolo unificado.

2. Fundamentação Teórica

2.1. Conjuntos de Dados de Vistas Esparsas

Essa nomenclatura refere-se, neste trabalho, aos conjuntos de dados imagéticos que possuem pouca (ou nenhuma) redundância e/ou variabilidade de poses de câmera referentes ao mesmo objeto. Áreas como histologia, holotomografia e microscopia confocal de fluorescência ilustram bem esse problema: a aquisição de imagens multi-vista é fisicamente limitada, biologicamente invasiva e estruturalmente esparsa por natureza [Xue et al. 2021].

2.2. Campos de Radiância Neural

Campos de Radiância Neural (*Neural Radiance Fields*, NeRF) utilizam-se de redes neurais do tipo MLP (*Multilayer Perceptron*) para aproximar uma função contínua no espaço 5D. Essa função recebe como entrada uma posição espacial $\mathbf{x} = (x, y, z)$ e uma direção de visualização $\mathbf{d} = (\theta, \phi)$, retornando a densidade volumétrica $\sigma(\mathbf{x})$ e a cor associada $\mathbf{c} = (r, g, b)$:

$$F_\theta : F_\theta \circ \gamma(\mathbf{x}, \mathbf{d}) \rightarrow (\sigma, \mathbf{c}), \quad \sigma \in \mathbb{R}_{\geq 0}, \quad \mathbf{c} \in [0, 1]^3$$

onde θ representa os pesos da rede neural e γ um codificador posicional.

2.3. Representações de Cena

Trabalhos subsequentes introduziram representações híbridas que desacoplam a estrutura espacial da rede neural, dado a viabilidade de alterar-se o *positional encoding* via codificação de fourier por um sistema de *hash encoding*. O Instant-NGP [Müller et al. 2022] propõe uma codificação por tabela de hash multiescala, que mapeia coordenadas espaciais em vetores de características de forma eficiente, reduzindo drasticamente o tempo de otimização por cena. O Nerfacto [Tancik et al. 2023] estende essa ideia combinando múltiplas otimizações comprovadas da literatura focando no equilíbrio entre qualidade visual e tempo de renderização em tempo real.

2.4. Renderização Volumétrica

Seja um campo de radiância neural F_θ , a cor esperada de um pixel é computada através de renderização volumétrica. Dado um raio $\mathbf{r}(t) = \mathbf{o} + t\mathbf{d}$ com limites de profundidade (t_n, t_f) , a cor resultante é dada pela integral:

$$\hat{C}(\mathbf{r}) = \int_{t_n}^{t_f} T(t) \sigma(\mathbf{r}(t)) \mathbf{c}(\mathbf{r}(t), \mathbf{d}) dt$$

onde $T(t) = \exp\left(-\int_{t_n}^t \sigma(\mathbf{r}(s)) ds\right)$ denota a transmitância acumulada ao longo do raio, ou seja, a probabilidade de o raio não atingir nenhuma partícula obstrutiva até a profundidade t . Na prática, por ser uma função contínua, essa integral é aproximada numericamente via *alpha compositing* sobre amostras discretas interpoladas ao longo de cada raio durante o treinamento.

2.5. Extrator de Características

O extrator de características se torna, portanto, responsável por codificar as imagens de entrada em representações que a rede neural possa condicionar. O PixelNeRF [Yu et al. 2021] utiliza uma ResNet (*Residual Neural Network*) pré-treinada para extrair mapas de características por imagem; dado um ponto 3D, sua projeção nas vistas de entrada recupera os vetores de características espaciais correspondentes, que são agregados e passados à MLP de radiância. Essa abordagem é local e opera por pixel, sem modelar explicitamente relações entre vistas. O GNT (Generalizable NeRF Transformer) [Wang et al. 2023] substitui: (i) o extrator de características por um *transformer* capaz de utilizar de mecanismos de atenção para angariar características mais globais ao objeto; (ii) a MLP de radiância também por um *transformer* que amostra pontos ao longo do raio e agrega informação entre vistas por meio de atenção cruzada, eliminando a dependência de uma função de volume explícita.

2.6. NeRFs Few-Shot vs. Per-Scene

Com o objetivo de reduzir a necessidade de múltiplas vistas durante o treinamento, surgiram abordagens conhecidas como NeRFs *few-shot*, capazes de generalizar a cena e produzir novas vistas a partir de poucas imagens, utilizando-se de diversos conceitos distintos aplicados aos componentes NeRF supracitados. Estas abordagens contrastam

frontalmente com os métodos *per-scene*. Enquanto modelos *per-scene* (como Instant-NGP) otimizam uma estrutura de dados de forma isolada e colapsam sob a escassez de vistas, arquiteturas *few-shot* e generalizáveis incorporam *priors* estruturais e semânticos aprendidos de grandes bases de dados. Essa distinção arquitetural torna-se indispensável em cenários onde a extração é severamente restrita.

3. Metodologia

Esta seção contempla a metodologia adotada para a realização dos experimentos, incluindo a descrição dos conjuntos de dados utilizados, os modelos de NeRF selecionados para o estudo comparativo, as métricas de avaliação aplicadas e o ambiente computacional onde os testes foram conduzidos.

Modelos sem integração nativa ao Nerfstudio (PixelNeRF e GNT) foram portados para o framework seguindo sua interface modular, viabilizar a sua respectiva comparação. A seguir, apresentam-se os modelos selecionados.

3.1. Modelos Selecionados

Neste trabalho, são avaliados modelos representativos para reconstrução de campos de radiância neural em cenários de poucas vistas (*few-shot*), contemplando diferentes paradigmas arquiteturais e estratégias de aprendizado. Especificamente, consideram-se:

1. PixelNeRF [Yu et al. 2021], que utiliza redes neurais convolucionais para extrair características espaciais das imagens e inseri-las no renderizador através de interpolação e projeção;
2. Generalizable NeRF Transformer (GNT) [Wang et al. 2023], que emprega mecanismos de atenção (*Transformers*) em ambos os componentes NeRF, substituindo tanto o extrator de características quanto o renderizador diferenciável por módulos baseados em atenção cruzada;

Para fins de linha de base (baseline) comparativa, este estudo também avalia métodos *per-scene* sob regime de dados limitados:

1. Instant-NGP [Müller et al. 2022], que substitui a MLP tradicional por uma codificação em tabela de hash multiescala, permitindo otimização por cena em tempo significativamente reduzido; e
2. Nerfacto [Tancik et al. 2023], modelo focado em eficiência que agrega as melhores heurísticas da literatura para proporcionar alta qualidade e treinamento rápido.

A fim de justificar a seleção das linhas de base, ressalta-se a ausência de outras arquiteturas seminais no protocolo de avaliação. A restrição aos modelos selecionados visa manter o foco no contraste metodológico entre abordagens generalizáveis (via extração de características) e estruturas explícitas otimizadas por cena, evitando a explosão combinatória do estudo. A seguir, detalham-se as motivações técnicas para a exclusão de arquiteturas proeminentes:

- **RegNeRF:** Embora seja o estado da arte em cenários de poucas vistas, sua premissa central baseia-se na aplicação de *priors* geométricos e na regularização de semântica e profundidade em poses não observadas, frequentemente utilizando fluxos normalizadores (*normalizing flows*). Como o escopo deste trabalho reside

em avaliar a capacidade intrínseca de generalização dos extratores de características (CNNs vs. Transformadores) e a eficiência estrutural de representações por *hash*, a inclusão de um método fortemente baseado em regularização de otimização desviaria o foco analítico.

- **MVSNeRF:** Apesar de ser um modelo generalizável robusto, sua arquitetura fundamenta-se na construção de volumes de custo 3D (*cost volumes*) baseados em princípios de *Multi-View Stereo* (MVS). Esta formulação impõe uma dinâmica de uso de memória e um paradigma de reconstrução geométrica que diferem substancialmente da codificação direta por projeção 2D (PixelNeRF) ou da agregação puramente atencional (GNT), inviabilizando uma omaração equitativa no que tange ao *footprint* de VRAM.
- **Mip-NeRF 360:** Projetado especificamente para mitigar o problema de aliasing e parametrizar o espaço de forma não linear em cenas abertas e irrestritas (*unbounded 360-degree*). Dado que o protocolo experimental deste estudo adota o dataset LLFF, caracterizado majoritariamente por capturas frontais de profundidade delimitada (*forward-facing*), a principal contribuição do Mip-NeRF 360 torna-se mecanicamente subutilizada. Ademais, sem acoplamento a estratégias de regularização *few-shot*, o modelo sofre degradação análoga aos métodos *per-scene* já representados de forma mais eficiente pelo Instant-NGP e Nerfacto.

A seleção e exclusão dos modelos supracitados visa proporcionar uma análise abrangente entre diferentes abordagens, cobrindo métodos baseados em CNNs, transformadores, reconstrução volumétrica explícita e modelos generativos baseados em representações por *hash per-scene*. Essa diversidade permite avaliar a qualidade de reconstrução em cenários com vistas limitadas e o compromisso entre generalização e custo computacional, bem como o impacto de estratégias distintas nos três regimes de avaliação considerados, como observado na seção 3.2.

3.2. Regimes Explorados

Os experimentos foram organizados em três regimes:

- **Per-Scene:** Representa o limite superior de fidelidade visual, no qual os modelos são otimizados a partir do zero utilizando a totalidade das imagens disponíveis para aquela cena específica, demandando um tempo de convergência expressivo em troca de alta qualidade de reconstrução;
- **Test-Time Adaptation (TTA):** Constitui um regime intermediário e eficiente sob a perspectiva temporal, em que de 3 a 10 imagens da nova cena alimentam o modelo generalizável pré-treinado por meio de poucos passos de sintonia fina (*fine-tuning*), permitindo a adaptação rápida e a correção de discrepâncias geométricas com baixo custo computacional;
- **Zero-Shot:** Consiste no paradigma ideal para cenários com restrições extremas de tempo de processamento e energia, em que a inferência é realizada instantaneamente a partir dos pesos genéricos pré-carregados, sem demandar qualquer etapa de treinamento ou otimização local na nova cena.

3.3. Implementação no Nerfstudio

Os modelos foram implementados no framework *Nerfstudio* [Tancik et al. 2023], seguindo sua arquitetura modular. As adaptações concentraram-se nos componentes Da-

taManager e Pipeline, responsáveis pelo carregamento das vistas de entrada e pela agregação das características multi-vista, respectivamente, mantendo inalterados os módulos de renderização e avaliação nativos do framework. A adoção de um framework unificado assegura equivalência no protocolo de avaliação entre os modelos, eliminando variáveis de implementação que poderiam comprometer a comparação, visto que o *Nerfstudio* oferece, ademais, um conjunto de utilitários aproveitados neste trabalho:

1. visualização em tempo real por meio de interface gráfica interativa, permitindo monitorar o treinamento e inspecionar qualitativamente os resultados de renderização durante o processo;
2. aceleração via GPU com suporte a CUDA, integrada à biblioteca *tiny-cuda-nn* [Müller 2021], que fornece implementações otimizadas de MLPs e codificações de entrada diretamente em kernels CUDA, com ganho de desempenho reportado entre $5\times$ e $30\times$ em relação a implementações PyTorch convencionais, dependendo da arquitetura e do cenário de uso; e
3. infraestrutura de logging e exportação de métricas, incluindo salvamento de checkpoints e integração com *Weights & Biases*, que padroniza o registro dos experimentos entre os diferentes modelos.

Dentre os modelos avaliados, o Instant-NGP e o Nerfacto encontram-se nativamente integrados ao *Nerfstudio*, dispensando adaptações de implementação. Os demais modelos (PixelNeRF e GNT) foram portados para o framework a partir de suas implementações originais, com adaptações nos componentes de *DataManager*, *Pipeline* e *model* para conformidade com a interface do *Nerfstudio*, ambos utilizando-se do otimizador Adam (otimizado pelo *tinycudann*) com *learning rate* $\eta = 1^{-3}$ e *weight decay* = 0.0.

As implementações foram guiadas pelas descrições metodológicas dos trabalhos originais, mantendo equivalência funcional. A implementação completa encontra-se disponível em <https://github.com/felipe-gsilva/few-shot-nerfs>.

3.4. Protocolo Experimental

Os experimentos foram conduzidos sobre o dataset LLFF (*Local Light Field Fusion*) [Mildenhall et al. 2019], composto por cenas de objetos reais capturadas com câmera em movimento frontal. A escolha pelo LLFF em detrimento de alternativas tradicionais como o DTU baseia-se diretamente nas severas restrições de hardware físico do presente estudo. Especificamente, o processamento dos volumes de custo tridimensionais (*cost volumes*) exigidos pelo DTU em sua resolução original demanda um volume de memória gráfica que excede a capacidade de 6 GB de VRAM da GPU utilizada. Dessa forma, o LLFF apresenta-se como a única opção viável que concilia relevância científica com a limitação de recursos físicos, sendo compatível com o protocolo de avaliação clássico de [Niemeyer et al. 2022]. Reserva-se, portanto, para teste as imagens cujo índice é múltiplo de 8 (llffhold=8), totalizando entre 5 e 8 imagens de teste por cena. As N vistas de treinamento ($N \in \{3, 6, 10\}$) são amostradas uniformemente das imagens remanescentes.

A seleção das vistas de treino foi realizada por duas estratégias distintas: (i) *uniform*, em que as vistas são amostradas por interpolação linear sobre os índices do dataset, distribuindo-as uniformemente ao longo da trajetória da câmera; e (ii) *random*, em que as vistas são sorteadas aleatoriamente com semente fixa, garantindo reprodutibilidade. A

comparação entre as duas estratégias permite avaliar a sensibilidade dos modelos à distribuição espacial das vistas de entrada.

Tabela 1. Impacto da estratégia de seleção de vistas de treino (*uniform* vs. *random*) sobre a qualidade visual média no dataset LLFF, avaliado no regime TTA com $N = 10$ vistas. Resultados reportado sobre a cena *fern*.

Modelo	Split	PSNR (dB) $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$	Δ PSNR (<i>unif.</i> – <i>rand.</i>)
PixelNeRF	Uniform	6.98	0.047	0.846	+0.54
	Random	6.44	0.042	0.840	
GNT	Uniform	10.34	0.179	0.738	+0.15
	Random	10.19	0.184	0.742	
Instant-NGP	Uniform	13.57	0.231	0.627	+0.06
	Random	13.51	0.229	0.630	
Nerfacto	Uniform	12.04	0.227	0.809	+0.11
	Random	11.93	0.226	0.865	

As imagens restantes foram divididas proporcionalmente entre conjuntos de validação e teste, também com semente fixa, assegurando que as vistas de teste sejam idênticas entre todos os modelos e estratégias de split, eliminando variáveis de avaliação que poderiam comprometer a comparação. As métricas finais são reportadas exclusivamente sobre o conjunto de teste, sem sobreposição com as vistas de treino. Todos os experimentos foram executados em uma GPU NVIDIA GeForce GTX 1660 Super (6GB de VRAM), com CUDA 12.6 e driver 610.43.02. Para garantir reprodutibilidade em diferentes arquiteturas, utilizou-se contêineres Docker com o runtime NVIDIA para garantir isolamento do ambiente e reprodutibilidade entre diferentes hosts com GPU compatível.

3.5. Métricas de Avaliação

A avaliação dos modelos contempla três dimensões complementares: qualidade visual, eficiência computacional e pegada de memória. Para a qualidade visual, são empregadas três métricas amplamente adotadas na literatura de síntese de novas vistas: (i) PSNR (*Peak Signal-to-Noise Ratio*), que mede a fidelidade pixel a pixel entre a imagem renderizada e a imagem de referência em escala logarítmica, sendo sensível a erros de brilho e cor; (ii) SSIM (*Structural Similarity Index Measure*) [Wang et al. 2004], que avalia a similaridade estrutural entre imagens considerando luminância, contraste e estrutura, sendo mais correlacionado com a percepção humana do que o PSNR; e (iii) LPIPS (*Learned Perceptual Image Patch Similarity*) [Zhang et al. 2018] usando a rede VGG (Visual Geometry Group) como extrator de características, seguindo o protocolo de [Niemeyer et al. 2022] para quantificar a distância perceptual entre imagens (valores menores indicam maior similaridade perceptual). Para a eficiência computacional, é medida a taxa de renderização em quadros por segundo (*fps*), avaliada durante a inferência sobre as câmeras do conjunto de teste. Para a pegada de memória, é reportado o footprint de parâmetros do modelo, calculado como a soma do produto entre o número de parâmetros e o tamanho de cada elemento em bytes. Também comparou-se os respectivos tamanhos de parâmetros com a quantidade de memória alocada no torch naquele dado momento.


Como o ambiente de GPU é controlado (reservado pelo ambiente docker), possíveis outros processos simultâneos não adicionaram ruído às métricas de avaliação.

As avaliações de qualidade visual são realizadas sobre o conjunto de teste gerado pelo protocolo de split descrito na Seção 3.4, utilizando o *dataloader* de avaliação do *Nerfstudio* (`fixed_indices_eval_dataloader`), que itera sobre câmeras fixas e compara as imagens renderizadas (`outputs["rgb"]`) com as imagens de referência (`batch["image"]`) sem amostras das vistas de treino.

4. Experimentos e Resultados

A seguir, destacam-se os principais resultados do treinamento, que levou, ao todo, cerca de 90 horas para ser completado. A Figura 1 ilustra o protocolo de execução adotado. Segmenta-se esta seção entre uma análise quantitativa, qualitativa e computacional, respectivamente.

Figura 1. Protocolo de execução experimental. As caixas superiores representam as etapas do pipeline; as ramificações inferiores detalham as variantes de configuração (estratégia de split, regime de treino) e as métricas coletadas. Todo o ambiente foi isolado via contêiner Docker com GPU reservada.



4.1. Análise Quantitativa

A análise quantitativa seguiu o protocolo experimental descrito na Seção 3, comparando as métricas LPIPS, SSIM e PSNR (Seção 3.5) entre todos os modelo e regimes de treino. A Tabela 2 apresenta as métricas escolhidas:

Tabela 2. Avaliação quantitativa da qualidade visual no dataset LLFF. As setas indicam se valores maiores ($\uparrow$) ou menores ($\downarrow$) representam desempenho superior. Negrito indica o melhor resultado dentro de cada regime; sublinhado indica o segundo melhor.

Regime	Modelo	PSNR (dB) $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$
Zero-Shot	PixelNeRF	5.75	0.065	0.850
	GNT	10.34	0.179	0.738
TTA ($N = 3$)	PixelNeRF	6.60	0.059	0.829
	GNT	10.19	0.184	0.742
TTA ($N = 6$)	PixelNeRF	6.52	0.060	0.831
	GNT	10.19	0.184	0.742
TTA ($N = 10$)	PixelNeRF	6.98	0.047	0.846
	GNT	10.34	0.179	0.738
Per-Scene (100%)	Instant-NGP	13.57*	0.440*	0.507*
	Nerfacto	12.04 / 26.25*	0.227 / 0.843*	0.809 / 0.205*

* Resultados avaliados no downscale 8 (resolução nativa de treino dos modelos *per-scene*). Os demais resultados reportados referem-se ao downscale 4. Para o Nerfacto, reporta-se no formato: *downscale 4 / downscale 8*.

Como referência externa, a Tabela 3 compila resultados reportados pelo *NerfBaselines* [Kulhanek and Sattler 2025] para o LLFF, um dataset predominantemente *forward-facing* para o qual métodos NeRF costumam empregar parametrização em espaço NDC. Estes números são apresentados apenas como comparativo de literatura (protocolo/hardware podem divergir do presente estudo).

Tabela 3. Resultados no LLFF reportados pelo *NerfBaselines* [Kulhanek and Sattler 2025]. "Time" refere-se ao tempo total de treinamento reportado e "GPU mem." ao pico de memória alocada durante o treino.

Método	PSNR (dB) $\uparrow$	SSIM $\uparrow$	LPIPS (VGG) $\downarrow$	Time	GPU mem. (GB)
Mip-NeRF 360	26.59	0.846	0.168	9h 55m 23s	104.98
TensoRF	26.68	0.834	0.202	31m 32s	20.38

4.2. Análise Qualitativa

A análise qualitativa seguiu as estruturas do split (3.4), sendo possíveis renderizações do volume em projeções tanto ortográficas quanto perspectivas. Para facilitar a identificação visual, optou-se por utilizar o acúmulo dos raios em projeção perspectiva, requerindo à rede tanto vistas já conhecidas (com os dados de câmera existentes) quanto novas vistas (o objeto de estudo deste trabalho). Destaca-se, a seguir, os principais resultados visuais:



Figura 2. Comparação qualitativa no regime TTA (10 vistas) para a cena "Fern" do dataset LLFF.

4.3. Trade-offs Computacionais

Tabela 4. Comparativo de custo computacional e pegada de memória. O tempo de treinamento refere-se à convergência da cena (ou adaptação no caso TTA). O "Tamanho da Rede" indica o footprint estático alocado, enquanto o "Pico Torch" demonstra o pico real de memória na GPU aferido dinamicamente durante a inferência. A taxa de FPS foi medida na renderização do conjunto de teste.

Modelo	Regime	Tempo de Treino	Tamanho da Rede (GB)	Pico Torch (GB)	Inferência (FPS)
PixelNeRF	Zero-Shot (0)	N/A (Pré-treinado)	1.93	3.42	0.006
GNT	Zero-Shot (0)	N/A (Pré-treinado)	1.93	0.19	0.008
PixelNeRF	TTA (10)	12 min 42 s	1.93	3.42	0.006
GNT	TTA (10)	06 min 54 s	1.93	0.19	0.008
Instant-NGP	Per-Scene	41 min 02 s	1.30	-	0.214
Nerfacto	Per-Scene	21 min 52 s	1.30	0.20	0.394

Por fim, ressalta-se que todos os experimentos foram executados de forma única e exclusiva sobre a cena *fern* do conjunto de dados LLFF. Essa decisão metodológica justifica-se pelo elevado custo de processamento exigido pelos modelos sob regime de Test-Time Adaptation (TTA), bem como pelo longo tempo total necessário para a convergência das demais variantes. Dessa forma, a cena *fern* foi adotada como um estudo de caso representativo para viabilizar a validação completa do pipeline sob as restrições práticas de hardware, servindo como base sólida antes de uma eventual expansão para as demais cenas do dataset.




Figura 3. Trade-off entre Fidelidade Visual (PSNR) e Consumo de VRAM no regime de 10 vistas / por cena). O quadrante superior esquerdo representa a região ideal (alta qualidade, baixo custo).

5. Conclusões

Este trabalho apresentou uma análise comparativa entre modelos NeRF generalizáveis (PixelNeRF, GNT) e modelos de otimização por cena (Instant-NGP, Nerfacto) em regimes de vistas esparsas, sob protocolo unificado no framework Nerfstudio. Os resultados parciais obtidos sobre o dataset LLFF revelam tendências que permitem delinear conclusões relevantes sobre os *trade-offs* entre fidelidade visual, generalização de escala espacial e custo computacional.

No eixo de qualidade visual, os resultados corrigidos — obtidos após a identificação e resolução de um bug sistemático no carregador de checkpoints que anteriormente provocava avaliações redundantes do mesmo checkpoint — revelam o comportamento esperado das diferentes arquiteturas. Os modelos generalizáveis exibem robustez notável sob diferentes resoluções: o GNT mantém um desempenho estável em torno de 10,34 dB de PSNR e 0,738 de LPIPS tanto no downscale 8 quanto no downscale 4, evidenciando a eficácia da agregação global por atenção cruzada em seu extrator de características. O PixelNeRF demonstra uma evolução coerente sob Test-Time Adaptation (TTA), subindo de 5,75 dB (Zero-Shot) para 6,98 dB ($N = 10$).

Em contrapartida, os modelos *per-scene* evidenciam uma forte dependência da escala de treinamento. Quando avaliado em sua resolução nativa de treino (downscale 8), o Nerfacto atinge a marca superior de 26,25 dB de PSNR e 0,843 de SSIM. Contudo, sob downscale 4, seu desempenho sofre uma severa degradação, caindo para 12,04 dB de PSNR e 0,227 de SSIM. Esse fenômeno realça a vulnerabilidade intrínseca de representações implícitas/híbridas otimizadas localmente (como as tabelas de hash multiescala), que não generalizam para escalas espaciais distintas daquelas vistas em treino, ao passo que os modelos generalizáveis providos de redes convolucionais e mecanismos de atenção global acomodam variações de resolução de maneira inerente.

Contudo, a análise computacional revela um *trade-off* não trivial. Os modelos generalizáveis dispensam otimização por cena no regime *zero-shot* e requerem adaptação mínima no TTA (12 min para PixelNeRF; ~ 7 min para GNT), enquanto os modelos *per-scene* demandam tempos de convergência significativamente maiores (~ 22 min para Nerfacto; ~ 41 min para Instant-NGP com 10 vistas). Em contrapartida, os modelos *per-scene* apresentaram taxas de inferência superiores (0,35 FPS para Nerfacto vs. 0,02 FPS para PixelNeRF), com menor consumo de VRAM (1,30 GB vs. 1,93 GB). Esses resultados indicam que, em cenários onde a latência de inferência e o *footprint* de memória são críticos, a exemplo de aplicações *mobile* ou sistemas embarcados, os métodos *per-scene* podem ser preferíveis mesmo com o custo adicional de treinamento.

É necessário ressaltar que os resultados reportados são parciais, restritos à cena *fern* do LLFF, e a generalização para o conjunto completo de 8 cenas requer execuções adicionais. O desempenho excepcionalmente baixo do PixelNeRF ($< 7,0$ dB) indica limitações inerentes de sua arquitetura local baseada em projeção 2D de características em vistas extremamente esparsas sem modelagem atencional de contexto global. Além disso, a estabilidade das métricas de TTA do GNT revela a robustez inerente da sua agregação baseada em transformadores.

Como trabalhos futuros, pretende-se: (i) completar a avaliação sobre as 8 cenas do LLFF, incluindo o regime *per-scene* com 100% das vistas (ii) investigar a integração

de estratégias de regularização geométrica (e.g., *depth priors*) aos modelos generalizáveis para mitigar a degradação observada; e (iii) estender o protocolo para datasets com geometrias mais desafiadoras, como o DTU, avaliando a robustez das conclusões sob diferentes distribuições de cena.

Referências

- Adobe (2025). *Substance 3D Viewer (beta)*. Computer Software.
- Hedman, P., Srinivasan, P. P., Mildenhall, B., Barron, J. T., and Debevec, P. (2021). Baking neural radiance fields for real-time view synthesis.
- Heo, H., Kim, T., Lee, J., Lee, J., Kim, S., Kim, H., and Kim, J.-H. (2023). Robust camera pose refinement for multi-resolution hash encoding.
- Kerbl, B., Kopanas, G., Leimkühler, T., and Drettakis, G. (2023). 3d gaussian splatting for real-time radiance field rendering. *ACM Transactions on Graphics*, 42(4).
- Kulhanek, J. and Sattler, T. (2025). Nerfbaselines: Consistent and reproducible evaluation of novel view synthesis methods.
- Mildenhall, B., Srinivasan, P. P., Ortiz-Cayon, R., Kalantari, N. K., Ramamoorthi, R., Ng, R., and Kar, A. (2019). Local light field fusion: Practical view synthesis with prescriptive sampling guidelines.
- Müller, T. (2021). tiny-cuda-nn. <https://github.com/NVlabs/tiny-cuda-nn>. Version 1.7, BSD-3-Clause License.
- Müller, T., Evans, A., Schied, C., and Keller, A. (2022). Instant neural graphics primitives with a multiresolution hash encoding. *ACM Transactions on Graphics*, 41(4):1–15.
- Niemeyer, M., Barron, J. T., Mildenhall, B., Sajjadi, M. S., Geiger, A., and Radwan, N. (2022). Regnerf: Regularizing neural radiance fields for view synthesis from sparse inputs. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 5480–5490.
- Schwarz, K., Liao, Y., Niemeyer, M., and Geiger, A. (2021). Graf: Generative radiance fields for 3d-aware image synthesis.
- Tancik, M., Weber, E., Ng, E., Li, R., Yi, B., Wang, T., Kristoffersen, A., Austin, J., Salahi, K., Ahuja, A., Mcallister, D., Kerr, J., and Kanazawa, A. (2023). Nerfstudio: A modular framework for neural radiance field development. In *Special Interest Group on Computer Graphics and Interactive Techniques Conference Conference Proceedings, SIGGRAPH '23*, page 1–12. ACM.
- Wang, Z., Bovik, A. C., Sheikh, H. R., and Simoncelli, E. P. (2004). Image quality assessment: from error visibility to structural similarity. *IEEE transactions on image processing*, 13(4):600–612.
- Wang, Z., Varma, M., Wang, P., Chen, X., Chen, T., and Venugopalan, S. (2023). Is attention all that nerf needs?
- Wu, H., Xiao, B., Codella, N., Liu, M., Dai, X., Yuan, L., and Zhang, L. (2021). Cvt: Introducing convolutions to vision transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 22–31.
- Xue, Y., Ye, J., Zhou, Q., Long, L. R., Antani, S., Xue, Z., Cornwell, C., Zaino, R., Cheng, K. C., and Huang, X. (2021). Selective synthetic augmentation with histogan for improved histopathology image classification. *Medical Image Analysis*, 67:101816.
- Yu, A., Ye, V., Tancik, M., and Kanazawa, A. (2021). pixelnerf: Neural radiance fields from one or few images.

Zhang, R., Isola, P., Efros, A. A., Shechtman, E., and Wang, O. (2018). The unreasonable effectiveness of deep features as a perceptual metric. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 586–595.