

Uma Análise Qualitativa e Computacional de NeRFs Few-Shot aplicadas em Conjunto de Dados de Vistas Esparsas

Felipe G. da Silva¹

¹Departamento de Ciências da Computação e Estatística – UNESP
CEP: 15054-000 – São José do Rio Preto – SP – Brazil

`felipe-gomes.silva@unesp.br`

Abstract. *This work compares hybrid NeRFs based on ViT and CNN applied to sparse-view datasets, evaluating the impact of these feature extraction architectures on novel view synthesis performance. Through a quantitative analysis using visual fidelity (PSNR, SSIM, LPIPS) and computational efficiency metrics (convergence time, VRAM footprint, inference time), this study highlights the trade-offs between the global generalization of Transformers and the local processing efficiency of convolutions. Ultimately, it aims to guide the selection of 3D rendering models for practical scenarios often constrained by hardware limitations and data scarcity.*

Resumo. *Esse trabalho apresenta uma comparação entre NeRFs híbridas baseadas em ViT e CNN aplicadas em conjuntos de dados com vistas esparsas e avalia o impacto dessas arquiteturas de extração de características no desempenho em síntese de novas vistas. Por meio de uma análise quantitativa baseada em métricas de fidelidade visual (PSNR, SSIM e LPIPS) e de eficiência computacional (tempo de convergência, consumo de VRAM e tempo de inferência), o estudo busca evidenciar os trade-offs entre a capacidade de generalização global dos Transformers e a eficiência de processamento local das convoluções, visando auxiliar na seleção de modelos de renderização 3D em cenários práticos, os quais são frequentemente marcados por restrições de hardware e escassez de dados.*

1. Introdução

Modelos de campos de radiância neural (NeRF) conquistaram, nos anos recentes, um papel muito importante, tanto na indústria, quanto na academia, atingindo resultados hiper-realistas sobre geração de novas vistas [Kerbl et al. 2023, Tancik et al. 2023, Adobe 2025]. Entretanto, as mais avançadas técnicas de renderização neural exigem uma grande quantidade de: (i) poder computacional; (ii) múltiplas vistas no conjunto de dados. Ambos os desafios supracitados tendem a impedir que aplicações mais simples, como escaneamento *mobile* de objetos, provador virtual, geração de assets 3D e síntese em datasets pequenos, sejam aproveitados. É com tal problemática que projetos como Instant-NGP (*Instant Neural Graphics Primitives*), MeRF (*Memory-Efficient Neural Radiance Field*), Pixel-Nerf, Gnt (*Generalizable Nerf Transformer*) [Müller et al. 2022, Reiser et al. 2023, Yu et al. 2021, Wang et al. 2023], entre outros, tentam expandir o estado da arte e, conseqüentemente, abordam temas partilhados, como: (i) *encoding* espacial de parâmetros [Müller et al. 2022, Reiser et al. 2023];

(ii) uso de arquiteturas híbridas entre Convolutional Neural Networks (CNN) e Vision Transformers (ViT) [Schwarz et al. 2021, Wu et al. 2021, Wang et al. 2023]; e (iii) pré-computação (*baking*) dos modelos em estruturas de menor pegada de memória [Reiser et al. 2023, Hedman et al. 2021].

Este trabalho tem, portanto, o objetivo de explorar o uso dos diferentes modelos de campos de radiância neural e suas respectivas técnicas de otimização, ao aplicá-las em alguns conjuntos de dados com vistas esparsas, promovendo uma análise exploratória entre desempenho computacional e qualidade dos volumes gerados. Para avaliar a fidelidade das reconstruções, serão utilizadas métricas de qualidade visual amplamente consagradas na literatura, como PSNR (*Peak Signal-to-Noise Ratio*), SSIM (*Structural Similarity Index Measure*) [Wang et al. 2004] e LPIPS (*Learned Perceptual Image Patch Similarity*) [Zhang et al. 2018]. Paralelamente, a quantificação do custo operacional basear-se-á em métricas de desempenho sistêmico, incluindo o tempo de convergência no treinamento, a velocidade de inferência e a pegada de memória (*memory footprint*), sobretudo o consumo de VRAM (*Video Random Access Memory*). Para que tais resultados fossem obtidos, utilizou-se a ferramenta Nerfstudio [Tancik et al. 2023], a qual exporta utilitários importantes como: (i) visualização em tempo real; (ii) implementação em cuda (ou seja, otimizada para gpu) já consolidada; e (iii) modelos prontos, com pré-computação e otimizações como as citadas previamente. Em suma, espera-se que esta investigação forneça um panorama consolidado sobre os *trade-offs* entre eficiência computacional e fidelidade visual, estabelecendo diretrizes claras para a viabilização e aplicação prática de modelos de síntese de novas vistas em cenários com restrições das mais diversas, especialmente de dados e de hardware.

2. Fundamentação Teórica

Conjuntos de Dados de Vistas Esparsas Essa nomenclatura refere-se, neste trabalho, aos conjuntos de dados imagéticos que possuem pouca (ou nenhuma) redundância e/ou variabilidade de diferentes poses de câmera referentes ao(s) mesmo(s) objeto(s) tridimensional(is). Áreas como histologia, holotomografia e microscopia confocal de fluorescência ilustram bem esse problema: a aquisição de imagens multi-vista é fisicamente limitada, biologicamente invasiva e estruturalmente esparsa por natureza [Xue et al. 2021].

Campos de Radiância Neural Diferentemente de métodos tradicionais de síntese de imagens, os Campos de Radiância Neural (*Neural Radiance Fields*, NeRF) utilizam-se de redes neurais do tipo MLP (*Multilayer Perceptron*) para aproximar uma função contínua no espaço 5D. Essa função recebe como entrada uma posição espacial $x = (x, y, z)$ e uma direção de visualização $d = (\theta, \phi)$, retornando a densidade volumétrica $\sigma(x)$ e a cor associada $c = (r, g, b)$:

$$f_{\theta}(x, d) \rightarrow (\sigma, c)$$

Essa representação permite modelar cenas tridimensionais de forma contínua, possibilitando a renderização de novas vistas a partir de diferentes pontos de observação. No entanto, modelar esta função como um simples modelo torna-se *anti-pattern*, visto que evita avançar em otimizações. Uma abordagem nova foi definida e estabeleceu-se que um Campo de Radiância Neural pode ser modelado por dois componentes principais: (i) uma

função contínua parametrizada por uma rede neural f_θ , responsável por mapear coordenadas espaciais e direções de visualização em propriedades volumétricas, além de extrair as devidas características tanto visuais quanto espaciais; (ii) um processo de renderização volumétrica diferenciável que integra essas propriedades ao longo de raios para formar imagens 2D [Mildenhall et al. 2020]. Neste trabalho, o principal objeto de estudo se dá no primeiro segmento, no entanto, modelos distintos empregam continuamente

Representações de Cena Enquanto a formulação original do NeRF parametriza a função f_θ exclusivamente por meio de MLPs, trabalhos subsequentes introduziram representações híbridas que desacoplam a estrutura espacial da rede neural. O Instant-NGP [Müller et al. 2022] propõe uma codificação por tabela de hash multiescala, que mapeia coordenadas espaciais em vetores de características de forma eficiente, reduzindo drasticamente o tempo de otimização por cena. O MERF [Reiser et al. 2023] estende essa ideia com representações tridimensionais esparsas orientadas à renderização em tempo real. Nesses modelos, o componente (i) é substituído por uma estrutura de dados explícita otimizável, sem capacidade de generalização entre cenas distintas.

Extrator de Características A capacidade de generalizar para novas cenas a partir de poucas vistas depende criticamente do extrator de características, responsável por codificar as imagens de entrada em representações que a rede neural possa condicionar. O PixelNeRF [Yu et al. 2021] utiliza uma ResNet pré-treinada para extrair mapas de características por imagem; dado um ponto 3D, sua projeção nas vistas de entrada recupera os vetores de características espaciais correspondentes, que são agregados e passados à MLP de radiância. Essa abordagem é local e opera por pixel, sem modelar explicitamente relações entre vistas. O GNT [Wang et al. 2023] substitui a MLP de radiância por um transformador que processa amostras ao longo do raio e agrega informação entre vistas por meio de atenção cruzada, eliminando a dependência de uma função de volume explícita.

NeRFs Few-Shot vs. Per-Scene Com o objetivo de reduzir a necessidade de múltiplas vistas durante o treinamento, surgiram abordagens conhecidas como NeRFs *few-shot*, que são capazes de generalizar a cena proposta e produzir novas vistas a partir de poucas imagens, cada uma à sua maneira, utilizando-se de diversos conceitos distintos aplicados aos componentes NeRF supracitados. Entre eles destacam-se: arquiteturas com extratores de características convolucionais (como o PixelNeRF, previamente citado) e, também, baseados em transformadores, como o GNT (*Generalizable NeRF Transformer*) [Wang et al. 2023]. É importante, no entanto, estabelecer a distinção entre dois regimes de operação presentes nos métodos avaliados. Modelos generalizáveis — como PixelNeRF e GNT — são, de fato, *few-shots* e capazes de reconstruir cenas complexas a partir de poucas imagens (quando em inferência, ainda precisando extrair características da cena durante o treino). Modelos por cena — como Instant-NGP e MERF — otimizam uma representação específica para cada cena individualmente, a partir das vistas disponíveis. Embora esses últimos não sejam *few-shot* objetivamente, sua inclusão no comparativo permite avaliar o compromisso entre qualidade de reconstrução e custo de otimização sob dados limitados.

3. Metodologia

Esta seção contempla a metodologia adotada para a realização dos experimentos, incluindo a descrição dos conjuntos de dados utilizados, os modelos de NeRF selecionados para o estudo comparativo, as métricas de avaliação aplicadas e o ambiente computacional onde os testes foram conduzidos.

Para viabilizar a comparação entre os modelos, implementou-se, individualmente, (caso não houvesse presença prévia) a integração do modelo proposto com a ferramenta NeRFStudio. A seguir, apresentam-se os modelos selecionados.

3.1. Modelos Selecionados

Neste trabalho, são avaliados modelos representativos para reconstrução de campos de radiância neural em cenários de poucas vistas (*few-shot*) e generalizáveis, contemplando diferentes paradigmas arquiteturais e estratégias de aprendizado. Especificamente, consideram-se:

1. PixelNeRF [Yu et al. 2021], que utiliza redes neurais convolucionais para extrair características espaciais das imagens e inseri-las no renderizador através de interpolação e projeção;
2. Generalizable NeRF Transformer (GNT) [Wang et al. 2023], que emprega mecanismos de atenção (*Transformers*) em ambos os componentes NeRF, substituindo tanto o extrator de características quanto o renderizador diferenciável por módulos baseados em atenção cruzada;

A efeito comparativo, também, serão avaliados aqui métodos *per-scene* sob regime de dados limitados:

1. Instant-NGP [Müller et al. 2022], que substitui a MLP tradicional por uma codificação em tabela de hash multiescala, permitindo otimização por cena em tempo significativamente reduzido; e
2. MERF [Reiser et al. 2023], que estende representações baseadas em hash com estruturas esparsas orientadas à renderização em tempo real.

A seleção desses modelos visa proporcionar uma análise abrangente entre diferentes abordagens, cobrindo métodos baseados em CNNs, transformadores, reconstrução volumétrica explícita e modelos generativos baseados em representações por hash *per-scene*. Essa diversidade permite avaliar não apenas a qualidade de reconstrução em cenários com vistas limitadas, mas também o compromisso entre generalização entre cenas e custo de otimização, bem como o impacto de estratégias distintas de extração de características nos três regimes de avaliação considerados, como pode ser visto na seção 3.3.

3.2. Implementação no Nerfstudio

Os modelos foram implementados no framework *Nerfstudio* [Tancik et al. 2023], seguindo sua arquitetura modular. Para cada abordagem, foram definidos componentes específicos de *DataManager*, *Model*, *Pipeline*, *Trainer* e configurações associadas, aproveitando ao máximo as abstrações pré-existentes do framework e realizando adaptações pontuais para garantir compatibilidade com os modelos selecionados. A adoção de um

framework unificado assegura equivalência no protocolo de avaliação entre os modelos, eliminando variáveis de implementação que poderiam comprometer a comparação, visto que o *Nerfstudio* oferece, ademais, um conjunto de utilitários aproveitados neste trabalho:

1. visualização em tempo real por meio de interface gráfica interativa, permitindo monitorar o treinamento e inspecionar qualitativamente os resultados de renderização durante o processo;
2. aceleração via GPU com suporte a CUDA, integrada à biblioteca *tiny-cuda-nn* [Müller 2021], que fornece implementações otimizadas de MLPs e codificações de entrada diretamente em kernels CUDA, com ganho de desempenho reportado entre $5\times$ e $30\times$ em relação a implementações PyTorch convencionais, dependendo da arquitetura e do cenário de uso; e
3. infraestrutura de logging e exportação de métricas, incluindo salvamento de checkpoints e integração com *Weights & Biases*, que padroniza o registro dos experimentos entre os diferentes modelos.

Dentre os modelos avaliados, o Instant-NGP e o MERF encontram-se nativamente integrados ao *Nerfstudio*, dispensando adaptações de implementação. Os demais modelos — PixelNeRF e GNT — foram portados para o framework a partir de suas implementações originais, com adaptações nos componentes de *DataManager* e *Pipeline* para conformidade com a interface do *Nerfstudio*. No caso do MERF, adicionalmente, foi utilizada a extensão *MERFStudio* [Song et al. 2024], disponível em <https://github.com/USTC3DV/MERFStudio>.

As implementações foram guiadas pelas descrições metodológicas dos trabalhos originais, mantendo equivalência funcional sempre que possível. A implementação completa encontra-se disponível em <https://github.com/felipe-gsilva/few-shot-nerfs>.

3.3. Protocolo Experimental

Os experimentos foram conduzidos sobre o dataset LLFF (*Local Light Field Fusion*) [Mildenhall et al. 2019], composto por cenas de objetos reais capturadas com câmera em movimento frontal. Para cada cena, foram avaliados três regimes de vistas de entrada: 3, 6 e 10 imagens de treino, representando cenários progressivamente menos restritivos de dados disponíveis.

A seleção das vistas de treino foi realizada por duas estratégias distintas: (i) *uniform*, em que as vistas são amostradas por interpolação linear sobre os índices do dataset (`np.linspace`), distribuindo-as uniformemente ao longo da trajetória da câmera; e (ii) *random*, em que as vistas são sorteadas aleatoriamente com semente fixa (`seed = 42`), garantindo reprodutibilidade. A comparação entre as duas estratégias permite avaliar a sensibilidade dos modelos à distribuição espacial das vistas de entrada.

As imagens restantes foram divididas proporcionalmente entre conjuntos de validação e teste, também com semente fixa, assegurando que as vistas de teste sejam idênticas entre todos os modelos e estratégias de split, eliminando variáveis de avaliação que poderiam comprometer a comparação. As métricas finais são reportadas exclusivamente sobre o conjunto de teste, sem sobreposição com as vistas de treino. Todos os experimentos foram executados em uma GPU NVIDIA GeForce RTX 4060 Ti (16 GB de VRAM), com CUDA 12.4 e driver 580.126.09.

3.4. Métricas de Avaliação

A avaliação dos modelos contempla três dimensões complementares: qualidade visual, eficiência computacional e pegada de memória.

Para a qualidade visual, são empregadas três métricas amplamente adotadas na literatura de síntese de novas vistas: (i) PSNR (*Peak Signal-to-Noise Ratio*), que mede a fidelidade pixel a pixel entre a imagem renderizada e a imagem de referência em escala logarítmica, sendo sensível a erros de brilho e cor; (ii) SSIM (*Structural Similarity Index Measure*) [Wang et al. 2004], que avalia a similaridade estrutural entre imagens considerando luminância, contraste e estrutura, sendo mais correlacionado com a percepção humana do que o PSNR; e (iii) LPIPS (*Learned Perceptual Image Patch Similarity*) [Zhang et al. 2018], que utiliza características extraídas por redes neurais profundas para quantificar a distância perceptual entre imagens (valores menores indicam maior similaridade perceptual). Para a eficiência computacional, é medida a taxa de renderização em quadros por segundo (*fps*), avaliada durante a inferência sobre as câmeras do conjunto de teste. Para a pegada de memória, é reportado o footprint de parâmetros do modelo, calculado como a soma do produto entre o número de parâmetros e o tamanho de cada elemento em bytes.

As avaliações de qualidade visual são realizadas sobre o conjunto de teste gerado pelo protocolo de split descrito na Seção 3.3, utilizando o *dataloader* de avaliação do *Nerfstudio* (`fixed_indices_eval_dataloader`), que itera sobre câmeras fixas e compara as imagens renderizadas (`outputs["rgb"]`) com as imagens de referência (`batch["image"]`) sem amostras das vistas de treino.

4. Experimentos e Resultados

5. Conclusões

Referências

- Adobe (2025). *Substance 3D Viewer (beta)*. Computer Software.
- Hedman, P., Srinivasan, P. P., Mildenhall, B., Barron, J. T., and Debevec, P. (2021). Baking neural radiance fields for real-time view synthesis.
- Kerbl, B., Kopanas, G., Leimkühler, T., and Drettakis, G. (2023). 3d gaussian splatting for real-time radiance field rendering. *ACM Transactions on Graphics*, 42(4).
- Mildenhall, B., Srinivasan, P. P., Ortiz-Cayon, R., Kalantari, N. K., Ramamoorthi, R., Ng, R., and Kar, A. (2019). Local light field fusion: Practical view synthesis with prescriptive sampling guidelines.
- Mildenhall, B., Srinivasan, P. P., Tancik, M., Barron, J. T., Ramamoorthi, R., and Ng, R. (2020). Nerf: Representing scenes as neural radiance fields for view synthesis.
- Müller, T. (2021). `tiny-cuda-nn`. <https://github.com/NVlabs/tiny-cuda-nn>. Version 1.7, BSD-3-Clause License.
- Müller, T., Evans, A., Schied, C., and Keller, A. (2022). Instant neural graphics primitives with a multiresolution hash encoding. *ACM Transactions on Graphics*, 41(4):1–15.

- Reiser, C., Peng, S., Liao, Y., and Barron, J. T. (2023). Merf: Memory-efficient radiance fields for real-time rendering of large-scale scenes. *ACM Transactions on Graphics (TOG)*, 42(4):1–14.
- Schwarz, K., Liao, Y., Niemeyer, M., and Geiger, A. (2021). Graf: Generative radiance fields for 3d-aware image synthesis.
- Song, K., Zeng, X., Ren, C., and Zhang, J. (2024). City-on-web: Real-time neural rendering of large-scale scenes on the web.
- Tancik, M., Weber, E., Ng, E., Li, R., Yi, B., Wang, T., Kristoffersen, A., Austin, J., Salahi, K., Ahuja, A., Mcallister, D., Kerr, J., and Kanazawa, A. (2023). Nerfstudio: A modular framework for neural radiance field development. In *Special Interest Group on Computer Graphics and Interactive Techniques Conference Conference Proceedings, SIGGRAPH '23*, page 1–12. ACM.
- Wang, Z., Bovik, A. C., Sheikh, H. R., and Simoncelli, E. P. (2004). Image quality assessment: from error visibility to structural similarity. *IEEE transactions on image processing*, 13(4):600–612.
- Wang, Z., Varma, M., Wang, P., Chen, X., Chen, T., and Venugopalan, S. (2023). Is attention all that nerf needs?
- Wu, H., Xiao, B., Codella, N., Liu, M., Dai, X., Yuan, L., and Zhang, L. (2021). Cvt: Introducing convolutions to vision transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 22–31.
- Xue, Y., Ye, J., Zhou, Q., Long, L. R., Antani, S., Xue, Z., Cornwell, C., Zaino, R., Cheng, K. C., and Huang, X. (2021). Selective synthetic augmentation with histogram for improved histopathology image classification. *Medical Image Analysis*, 67:101816.
- Yu, A., Ye, V., Tancik, M., and Kanazawa, A. (2021). pixelnerf: Neural radiance fields from one or few images.
- Zhang, R., Isola, P., Efros, A. A., Shechtman, E., and Wang, O. (2018). The unreasonable effectiveness of deep features as a perceptual metric. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 586–595.